

考虑有限处置能力和共载约束的多周期危险废物收运—处置协同优化

一、引言

随着新型工业化推进和全过程环境风险治理趋严，危化废弃物规范收运与安全处置已成为生态安全的重要议题。工业生产持续产生的此类废弃物具有毒性、易燃性或腐蚀性，储运或处理失控易引发环境污染与安全事故。现实中，产废节点分散、品类多样，产生、收运与处理难以同步；末端处置节点处理能力有限，且废物品类须与处理技术匹配。尽早收运虽可降低产废端库存风险，却可能增加车辆启用和行驶成本，并在处置能力不足时增加末端库存；跨期暂存可增加单次收运量，却会累积产废端风险。兼容品类共载有助于节约运力，但同一路段共载会产生载荷相关附加风险；分车运输则可能增加运力投入。因此，如何在有限处置能力与共载约束下，实现危化废弃物多周期收运处理的协同优化，兼顾经济性与安全性，是危化废弃物逆向物流亟待解决的问题。

与危化废弃物多周期收运处理相关的研究主要围绕多品类运输风险与跨期收运处理协同[6-9]展开。在多品类运输风险方面，Alumur 和 Kara[1]考虑废物与处理技术的匹配，联合优化设施选址与运输路径；Paredes-Belmar 等[2]研究不同品类共载对运输风险的影响；Rabbani 等[3]将废物不兼容约束纳入选址—路径模型。Wu 等[4]进一步刻画库存、运输及不同危险品的时空风险叠加，李政辉等[5]则从簇团网络出发研究原油供应风险联动，为多源风险建模提供参考。在跨期收运处理协同方面，Sheu[6]协调区域多源危废的运输、库存与处理活动；Elbek 和 Wöhlk[7]在滚动时域下安排可回收物收集与转运；Rabbani 等[8]构建随机多周期危废选址—路径—库存模型；和剑波等[9]联合优化多周期循环包装器具调度与越库配送，为库存与运输协同决策提供参考。

强化学习通过与环境交互学习决策策略，已应用于物流与供应链优化[10]。第一类研究通过逐步决策构造方案：Que 等[11]结合 Transformer 与近端策略优化（PPO）求解三维装箱问题；Tian 等[12]引入贝叶斯网络，优化具有时空约束的物流服务组合；向传凯等[13]利用车辆轮换与注意力解码生成众包取送货路径；王苓等[14]采用 PPO 求解连续泊位与岸桥动态调度问题；Chen 等[15]利用偏好驱动的多目标深度强化学习开展资源约束项目调度。第二类研究从已有解出发通过算子改进策略：Wu 等[16]采用自注意力网络学习路径改进启发式，Guan 等[17]结合协同注意力 Transformer 与 PPO 优化路径改进策略。

通过上述分析发现，现有研究对有限处置能力与共载约束下的多周期危险废物收运—处置协同优化仍缺乏充分讨论。一方面，多周期研究已考虑收运与库存的跨期衔接，但对兼容品类共载时风险随路段实际载荷变化的刻画仍显不足；另一方面，多品类运输研究关注品类兼容、共载风险或时空风险叠加，但与持续产废、双端库存结转及有限处理能力的结合尚不充分。因此，仍需将共载安排与跨期收运、车辆路径及末端处理统筹考虑，分析处置能力限制与共载约束对成本—风险权衡的共同影响。针对上述问题，本文在给定处理处置节点条件下，构建确定性多周期危化废弃物收运—处理混合整数线性规划模型，以经济成本和系统风险最小化为目标，统筹收运时机、车辆路径与处置节点选择，考虑双端库存、处理技术适配

及分品类处理能力，并依据各路段的分品类实际载荷刻画共载附加风险。在此基础上，设计 Transformer 引导的 PPO 邻域搜索算法（TPNS），从完整可行方案出发，学习邻域算子及操作对象的选择策略，结合可行性修复迭代改进方案。

二、问题描述与数学模型

（一）问题描述

考虑由危化废弃物产废节点、处理处置节点和同质车辆构成的多周期收运网络。为同时区分物理来源和危化废弃物类别，将每个“产废节点-危化废弃物类型”组合定义为一个收运任务节点。车辆在每个周期从某一处理处置节点空载出发，依次访问若干收运任务节点，完成收运后返回出发时的同一处理处置节点；运输途中不卸载。处理处置节点接收车辆送达的危化废弃物后，可在当期进行处理，未处理量结转至下一期。

每个周期按以下顺序推进：上期产废节点库存与本期新增量合并形成收运前库存；车辆执行收运路线；到货量与处理处置节点上期期末库存合并形成处理前库存；处理处置节点在技术和能力范围内进行处理；剩余量形成两端期末库存。（最忌讳一个东西在多个地方重复）

（二）模型假设

- （1）规划期内各期危化废弃物产生量、距离、单位距离事故率、处理技术与处理能力均为已知确定值；处理处置节点的位置和数量不作决策。
- （2）车辆同质且容量相同；每辆车每期至多执行一条闭合路线，路线从一个处理处置节点出发并返回该处理处置节点，途中不进行转运或卸载。
- （3）同一收运任务节点同一期至多由一辆车访问；一旦访问，车辆收走该实体当期全部可用库存，不允许部分收运或多车拆分。
- （4）不相容危化废弃物不得同车运输；两类兼容危化废弃物可以共载，但其在同一路段同时存在时产生与两类载荷之和相关的附加风险。
- （5）处理处置节点只能接收其具备相应处理技术的危化废弃物。危化废弃物到达后，处理处置节点按可用库存与当期处理能力两者的较小值进行处理，即当期尽可能处理。
- （6）产废节点和处理处置节点库存均不得超过各自容量；为避免规划期边界造成风险外移，最后一期两端库存必须清零。

（三）模型集合、参数与变量说明

表 1 集合与索引

符号	含义
I	危化废弃物产废节点集合，索引为 i
S	危化废弃物类型集合，索引为 s, r
J	给定处理处置节点集合，索引为 j
K	同质车辆集合，索引为 k
$T = \{1, \dots, H\}$	离散规划周期集合，索引为 t , H 为末期
$N = I \times S$	产废节点-危化废弃物类型收运任务节点集合，索引为 n, m
$V = J \cup N$	运输网络节点集合

符号	含义
$A \subseteq V \times V$	允许通行的有向弧集合
P	无序危化废弃物类型对集合，包含所有满足 $s < r$ 的类型对
$A^-(v), A^+(v)$	节点 v 的入弧集合与出弧集合
$o(n), s(n)$	收运任务节点 n 对应的产废节点与危化废弃物类型

表 2 参数

符号	含义
g_{ist}	产废节点 i 的类型 s 危化废弃物在周期 t 的产生量
I_{is0}^P, I_{is0}^F	产废节点和处理处置节点的初始库存
C_i^P, C_i^F	产废节点 i 和处理处置节点 j 的总储存容量
Q	单车容量
d_{ab}	弧 (a, b) 的运输距离
π_{ab}	弧 (a, b) 的单位距离事故率
c^v	车辆单期启用成本
c^d	单位运输距离成本
c_{is}^p	处理处置节点 j 处理单位类型 s 危化废弃物的成本
θ_{js}	处理处置节点 j 具备类型 s 危化废弃物处理技术时取 1，否则取 0
P_{jst}	处理处置节点 j 在周期 t 对类型 s 危化废弃物的处理能力
χ_{sr}	类型 s 与 r 允许同车运输时取 1，否则取 0
γ_{sr}	兼容类型 s 与 r 的成对共载附加风险系数
h_s	类型 s 危化废弃物的事故后果系数
ρ_{is}^P, ρ_{is}^F	产废节点和处理处置节点的单位期末库存风险系数
ε	用于识别有效收运的最小正量
δ_{ns}	s 为实体 n 对应的危化废弃物类型时取 1，否则取 0
b_C, b_R	同一可行参考方案的成本和风险尺度
α_C, α_R	成本和风险偏好权重，两者之和为 1
M^P	取货逻辑上界，取各产废节点总储存容量的最大值
M^L	载荷递推上界，取 $2Q$
M_j	处理处置节点线性化上界，不小于处理处置节点 j 的总储存容量及其最大处理能力
U_{jst}	处理处置节点 j 在周期 t 对类型 s 危化废弃物的有效处理能力，等于标称处理能力与技术适配参数的乘积

表 3 决策变量 ()

符号	含义
e_{kt}	车辆 k 在周期 t 启用时取 1，否则取 0
x_{abkt}	车辆 k 在周期 t 经过弧 (a, b) 时取 1，否则取 0
q_{nkt}	车辆 k 在周期 t 从收运任务节点 n 收运的数量
l_{nskt}	车辆 k 完成实体 n 的收运后所载类型 s 危化废弃物数量
F_{abskt}	车辆 k 在弧 (a, b) 上所载类型 s 危化废弃物数量

符号	含义
H_{abskt}	弧 (a, b) 上载有类型 s 危化废弃物时取 1，否则取 0
W_{absrkt}	弧 (a, b) 上同时载有类型 s 与 r 时取 1，否则取 0
G_{absrkt}	类型 s 与 r 同弧共载时两类载荷之和
B_{nt}^P, I_{nt}^P	实体 n 的收运前库存和期末库存
R_{jst}	处理处置节点 j 在周期 t 接收的类型 s 危化废弃物数量
B_{jst}^F, I_{jst}^F	处理处置节点 j 的处理前可用库存和期末库存
p_{jst}	处理处置节点 j 在周期 t 处理的类型 s 危化废弃物数量
ω_{jst}	表示处理处置节点最大处理规则的辅助变量

(三) 数学模型

基于上述符号，模型分别以经济成本和系统风险最小为目标，相关目标函数及约束条件如下。各式索引均按符号表所列集合取值，未引起歧义的全称量词从略。

$$\min TC = C^v + C^d + C^p \quad (1)$$

$$\min TR = R^{tr} + R^{co} + R^P + R^F \quad (2)$$

$$C^v = c^v \sum_{k \in K} \sum_{t \in T} e_{kt} \quad (3)$$

$$C^d = c^d \sum_{(a,b) \in A} \sum_{k \in K} \sum_{t \in T} d_{ab} x_{abkt} \quad (4)$$

$$C^p = \sum_{j \in J} \sum_{s \in S} \sum_{t \in T} c_{js}^p p_{jst} \quad (5)$$

$$R^{tr} = \sum_{(a,b) \in A} \sum_{s \in S} \sum_{k \in K} \sum_{t \in T} \pi_{ab} d_{ab} h_s F_{abskt} \quad (6)$$

$$R^{co} = \sum_{(a,b) \in A} \sum_{(s,r) \in P} \sum_{k \in K} \sum_{t \in T} \pi_{ab} d_{ab} \gamma_{sr} G_{absrkt} \quad (7)$$

$$R^P = \sum_{n \in N} \sum_{t \in T} \rho_{o(n),s(n)}^P I_{nt}^P \quad (8)$$

$$R^F = \sum_{j \in J} \sum_{s \in S} \sum_{t \in T} \rho_{js}^F I_{jst}^F \quad (9)$$

$$\sum_{j \in J} z_{jkt} = e_{kt}, \forall k \in K, t \in T \quad (10)$$

$$\sum_{(a,n) \in A} x_{ankt} = \sum_{(n,b) \in A} x_{nbkt} = y_{nkt}, \forall n, k, t \quad (11)$$

$$\sum_{(j,n) \in A} x_{jnkt} = \sum_{(n,j) \in A} x_{njkt} = z_{jkt}, \forall j, k, t \quad (12)$$

$$\sum_{n \in N} q_{nkt} \leq Q e_{kt}, \forall k, t \quad (13)$$

$$\sum_{k \in K} y_{nkt} \leq 1, \forall n, t \quad (14)$$

$$\varepsilon y_{nkt} \leq q_{nkt} \leq M^P y_{nkt}, \forall n, k, t \quad (15)$$

$$q_{nkt} \geq B_{nt}^P - M^P (1 - y_{nkt}), \forall n, k, t \quad (16)$$

$$\sum_{s \in S} l_{nskt} \leq Q y_{nkt}, \forall n, k, t \quad (17)$$

$$-M^L (1 - x_{jnkt}) \leq l_{nskt} - \delta_{ns} q_{nkt} \leq M^L (1 - x_{jnkt}), \forall j, n, s, k, t \quad (18)$$

$$-M^L (1 - x_{nmkt}) \leq l_{mskt} - l_{nskt} - \delta_{ms} q_{mkt} \leq M^L (1 - x_{nmkt}) \quad (19)$$

$$F_{abskt} = 0, \forall a \in J, (a, b) \in A, s, k, t \quad (20)$$

$$F_{abskt} \leq Q x_{abkt}, F_{abskt} \leq l_{askt}, F_{abskt} \geq l_{askt} - Q (1 - x_{abkt}), \forall a \in N \quad (21)$$

$$\varepsilon H_{abskt} \leq F_{abskt} \leq Q H_{abskt}, H_{abskt} \leq x_{abkt}, \forall (a, b) \in A, s, k, t \quad (22)$$

$$W_{absrkt} \leq H_{abskt}, W_{absrkt} \leq H_{abrkt}, W_{absrkt} \geq H_{abskt} + H_{abrkt} - 1 \quad (23)$$

$$G_{absrkt} \leq F_{abskt} + F_{abrkt}, G_{absrkt} \leq 2QW_{absrkt} \quad (24)$$

$$G_{absrkt} \geq F_{abskt} + F_{abrkt} - 2Q(1 - W_{absrkt}), \forall (a, b) \in A, (s, r) \in P, k, t \quad (25)$$

$$z_{jkt} + y_{nkt} \leq 1 + \theta_{j,s(n)}, \forall j, n, k, t \quad (26)$$

$$y_{nkt} + y_{mkt} \leq 1 + \chi_{s(n),s(m)}, \forall n < m, k, t \quad (27)$$

$$B_{n1}^P = I_{o(n),s(n),0}^P + g_{o(n),s(n),1}, \forall n \quad (28)$$

$$B_{nt}^P = I_{n,t-1}^P + g_{o(n),s(n),t}, \forall n, t = 2, \dots, H \quad (29)$$

$$I_{nt}^P = B_{nt}^P - \sum_{k \in K} q_{nkt}, \forall n, t \quad (30)$$

$$\sum_{s \in S} B_{(i,s),t}^P \leq C_i^P, \sum_{s \in S} I_{(i,s),t}^P \leq C_i^P, \forall i, t \quad (31)$$

$$R_{jst} = \sum_{k \in K} \sum_{n:(n,j) \in A} F_{njskt}, \forall j, s, t \quad (32)$$

$$B_{js1}^F = I_{js0}^F + R_{js1}, \forall j, s \quad (33)$$

$$B_{jst}^F = I_{js,t-1}^F + R_{jst}, \forall j, s, t = 2, \dots, H \quad (34)$$

$$p_{jst} \leq B_{jst}^F, p_{jst} \leq U_{jst}, \forall j, s, t \quad (35)$$

$$p_{jst} \geq B_{jst}^F - M_j(1 - \omega_{jst}), p_{jst} \geq U_{jst} - M_j\omega_{jst}, \forall j, s, t \quad (36)$$

$$I_{jst}^F = B_{jst}^F - p_{jst}, \forall j, s, t \quad (37)$$

$$\sum_{s \in S} B_{jst}^F \leq C_j^F, \sum_{s \in S} I_{jst}^F \leq C_j^F, \forall j, t \quad (38)$$

$$I_{nH}^P = 0, I_{jsH}^F = 0, \forall n, j, s \quad (39)$$

$$e, x, H, W, \omega \in B; q, l, F, G, B^P, I^P, R, B^F, I^F, p \geq 0 \quad (40)$$

式（1）和式（2）分别表示经济成本最小化目标和系统风险最小化目标。式（3）—（5）分别计算车辆启用、行驶和处理成本。式（6）—（9）分别计算运输事故风险、兼容品类共载附加风险，以及产废节点和处理处置节点的库存风险。其中，式（7）借鉴 Wu 等（2022）的风险叠加建模思路，刻画兼容品类共载产生的附加风险。[8] 式（10）—（14）为路径与车辆服务约束，规定车辆的处理处置节点选择、节点流量平衡、同一处置节点出发与返回、单车收运量上限，以及每个收运任务在每周至多由一辆车服务。式（15）—（21）为收运与载荷约束，明确节点访问与收运量之间的关系，要求车辆访问时收清该任务的当期可用库存，并描述分类型载荷沿行驶路径的变化，保证车辆不超载且空载出发。式（22）—（27）为共载与匹配约束，识别车辆在各行驶弧上承载的危化废弃物品类及两两共载量，保证所收运品类与处理处置节点的技术相匹配，并禁止不相容品类同车运输。式（28）—（31）为产废节点库存约束，描述危化废弃物持续产生、当期收运和跨期结转的过程，并限制收运前后的库存不超过节点容量。式（32）—（38）为处理处置节点流量、处理与容量约束，汇总各类危化废弃物的到货量，按照可用库存与分类型处理能力的较小值确定当期处理量，并保证处理前后的库存不超过设施容量。式（39）—（40）为期末清零与变量取值约束，要求规划期末两类节点均无剩余库存，并规定各类决策变量的取值范围。（还是多）

三、PPO-Transformer 求解方法

针对危化废弃物多周期收运处理问题，本文设计 PPO-Transformer 求解算法。算法从初始可行方案出发，根据当前状态选择邻域算子及操作对象，逐步调整收运安排。整体框架如

图 1 所示，下文依次介绍马尔科夫决策模型、动作选择与价值估计，以及基于 PPO 的训练与求解过程。

图 1 PPO-Transformer 求解框架

（一）收运方案改进的马尔科夫决策模型

在每轮决策中，智能体根据当前收运方案选择调整动作，环境执行该动作并反馈新的方案及奖励。本文将这一过程建模为马尔科夫决策模型。其中，决策步 l 表示方案的改进次数，与实际收运周期 t 不同。

1) 状态。第 l 个决策步的状态定义为：

$$s_l = (P_l, \omega, \eta_l, \xi_l, \theta). \quad (42)$$

其中， P_l 为当前可行方案，包含各周期车辆路线及其对应的收运、处理和库存信息； $\omega = (\omega_c, \omega_r)^T$ 为成本—风险偏好向量，满足 $\omega_c + \omega_r = 1$ 且两者非负； η_l 和 ξ_l 分别为搜索进度与连续未改进比例； θ 为实例参数，包括产生量、容量、处理能力、距离、风险系数及目标归一化所需的参考尺度。

2) 动作。动作 a_l 表示对当前方案的一次邻域调整，包括节点重定位、节点交换、2-opt、处理处置节点替换、服务周期移动、增加提前服务、按品类拆分路线和单节点拆分路线。各算子的具体定义见附录 A，所有调整均遵循同一周期内收运需求不可拆分的约束。

3) 状态转移。执行动作后，先对候选方案进行确定性修复，再验证其可行性。修复过程调整任务分配与路线，满足车辆容量、品类兼容和处理技术匹配等要求；随后按周期递推收运量、处理量及两端库存，检查设施容量、路网可达性和期末库存清零等约束。记修复后的候选方案为 $\tilde{P}_{l+1}$ ，则：

$$P_{l+1} = \begin{cases} \tilde{P}_{l+1}, & \text{动作有效且候选方案通过可行性验证,} \\ P_l, & \text{否则.} \end{cases} \quad (43)$$

完成方案更新后，同步更新 η_l 和 ξ_l 。这一转移允许接受暂时未改善目标的可行方案，以探索后续邻域；达到预设改进步数时结束该轮交互。

4) 奖励函数。对每个实例预先确定一个可行启发式参考方案 P^{ref} ，并在不同偏好、重启及整个训练与求解过程中保持该实例的参考方案不变。以其正的成本和风险值统一状态输入、训练奖励及方案评价的尺度，给定偏好下的评价目标为：

$$J_\omega(P) = \omega_c \frac{C(P)}{C(P^{\text{ref}})} + \omega_r \frac{R(P)}{R(P^{\text{ref}})}. \quad (44)$$

以相邻方案加权目标的下降量作为即时奖励。对于执行成功的动作，定义：

$$r_l^\omega = \omega_c \frac{C(P_l) - C(P_{l+1})}{C(P^{\text{ref}})} + \omega_r \frac{R(P_l) - R(P_{l+1})}{R(P^{\text{ref}})}. \quad (45)$$

加权目标降低时，奖励为正，反之为负。若执行成功但成本与风险均未发生变化，则给予较小惩罚；动作无效或修复失败时，给予较大惩罚，具体取值见附录 B。

（二）动作选择与价值估计

通过初始嵌入和多头注意力编码提取当前方案的特征信息，再由策略神经网络计算动作选择概率，由价值神经网络估计期望累计回报。

1. 初始嵌入层

为描述当前方案的收运、处理与库存状态及决策偏好，本文构建全局方案、成本—风险偏好、周期、车辆—周期、产废节点—品类—周期、处理处置节点—品类—周期及路线弧七类特征，其具体构成与处理方法详见附录 A。初始嵌入过程如下：

$$\mathbf{h}_i = W_{\tau_i}^E \mathbf{x}_i + \mathbf{b}_{\tau_i}^E. \quad (46)$$

其中， $\mathbf{x}_i$ 为第*i*组特征经尺度处理、拼接类型编号并补齐至 d_x 维后形成的特征信息向量， τ_i 表示其类型。 $\mathbf{h}_i$ 表示 $\mathbf{x}_i$ 经线性升维投影得到的 d_h 维初始嵌入向量， $W_{\tau_i}^E \in \mathbb{R}^{d_h \times d_x}$ 和 $\mathbf{b}_{\tau_i}^E \in \mathbb{R}^{d_h}$ 分别为该类型的投影矩阵和偏置向量。 M_l 为当前状态的特征信息向量数。

2. 基于多头注意力机制的编码神经网络

本文采用多头注意力机制[13]对特征信息进行编码，共设置 Z 个注意力头。对于第 e 个注意力头（ $e \in \{1, \dots, Z\}$ ），将特征向量 $\mathbf{h}_i$ 分别投影为查询向量 $\mathbf{q}_{i,e} = W_e^Q \mathbf{h}_i + \mathbf{b}_e^Q$ 、键向量 $\mathbf{k}_{i,e} = W_e^K \mathbf{h}_i + \mathbf{b}_e^K$ 和值向量 $\mathbf{v}_{i,e} = W_e^V \mathbf{h}_i + \mathbf{b}_e^V$ ，三者均为 d_e 维向量，其中 $d_e = d_h/Z$ 。 $W_e^Q, W_e^K, W_e^V \in \mathbb{R}^{d_e \times d_h}$ 为投影矩阵， $\mathbf{b}_e^Q, \mathbf{b}_e^K, \mathbf{b}_e^V \in \mathbb{R}^{d_e}$ 为偏置向量。第*i*个特征与第*j*个特征的配合度及相应的注意力输出为：

$$u_{ij,e} = \frac{\mathbf{q}_{i,e}^T \mathbf{k}_{j,e}}{\sqrt{d_e}},$$

$$\mathbf{h}'_{i,e} = \sum_{j=1}^{M_l} \frac{\exp(u_{ij,e})}{\sum_{j'=1}^{M_l} \exp(u_{ij',e})} \mathbf{v}_{j,e}. \quad (47)$$

其中， $u_{ij,e}$ 表示第 e 个注意力头中两个特征的配合度， $i, j \in \{1, \dots, M_l\}$ 。配合度经 Softmax 转换为注意力权重后，对各特征的值向量进行加权求和，得到第*i*个特征在该注意力头中的输出 $\mathbf{h}'_{i,e} \in \mathbb{R}^{d_e}$ 。

各注意力头并行完成上述计算后，将同一特征在各头中的输出拼接并进行线性融合，得到 $\mathbf{m}_i = W^O [\mathbf{h}'_{i,1}; \dots; \mathbf{h}'_{i,Z}] + \mathbf{b}^O$ ，其中 $[\cdot]$ 表示向量拼接， $W^O \in \mathbb{R}^{d_h \times d_h}$ 和 $\mathbf{b}^O \in \mathbb{R}^{d_h}$ 分别为融合层的权重矩阵和偏置向量。随后通过残差连接、层归一化和前馈神经网络得到编码结果：

$$\tilde{\mathbf{h}}_i = \text{LN}_1(\mathbf{h}_i + \mathbf{m}_i),$$

$$\hat{\mathbf{h}}_i = \text{LN}_2(\tilde{\mathbf{h}}_i + \text{FF}(\tilde{\mathbf{h}}_i)). \quad (48)$$

其中，LN表示层归一化，FF为包含两个线性层和 ReLU 激活函数的前馈神经网络，其参数在各特征之间共享。 $\tilde{\mathbf{h}}_i$ 为中间结果， $\hat{\mathbf{h}}_i \in \mathbb{R}^{d_h}$ 为第*i*个特征编码后的向量。最后对当前状态的 M_l 个编码向量进行平均池化，得到当前方案的聚合信息：

$$\bar{\mathbf{h}}_l = \frac{1}{M_l} \sum_{i=1}^{M_l} \hat{\mathbf{h}}_i. \quad (49)$$

3. 动作选择

策略神经网络根据聚合信息选择邻域算子及操作对象。将 $\bar{\mathbf{h}}_l$ 分别输入四个线性输出层，其中一个用于算子选择，其余三个用于操作对象选择，各层输出经 Softmax 转换为概率分布：

$$\mathbf{p}_l^{(q)} = \text{softmax}(W_q \bar{\mathbf{h}}_l + \mathbf{b}_q), q = 0, 1, 2, 3,$$

$$\pi_\theta(a_l | s_l) = p_{l,o_l}^{(0)} \prod_{q=1}^3 p_{l,u_l^{(q)}}^{(q)}. \quad (50)$$

训练时，从四个分布中分别采样并组合为一个动作。四组输出均依赖包含偏好信息的状态表示，各动作分量的符号定义见附录 A。

4. 价值估计

价值神经网络与策略神经网络共享初始嵌入层和注意力编码器，将聚合信息输入一个双输出线性层，分别估计成本和风险奖励的期望折扣累计值：

$$\mathbf{V}_\psi(s_l) = W_V \bar{\mathbf{h}}_l + \mathbf{b}_V = [V_\psi^c(s_l), V_\psi^r(s_l)]^T. \quad (51)$$

其中， θ 和 ψ 分别表示策略与价值网络参数。价值估计用于训练阶段的优势计算，求解时仅使用策略网络选择动作。

(三) 基于 PPO 的训练与求解

采用近端策略优化算法 PPO[12]训练上述网络。每轮从训练集中抽取实例，并为各条交互轨迹抽取一个成本—风险偏好；偏好在该轨迹内保持不变。智能体从预先保存的可行方案出发，按当前策略采集固定长度的状态、动作和奖励序列。

为训练双输出价值网络，分别保留式(45)中未加权的成本改善量和风险改善量，记为 r_l^c 与 r_l^r ，惩罚在两个分量中同等计入。对两个分量分别计算广义优势估计，设轨迹长度为 L ，则：

$$\begin{aligned} \delta_l^d &= r_l^d + \gamma V_{\psi_{\text{old}}}^d(s_{l+1}) - V_{\psi_{\text{old}}}^d(s_l), \\ A_l^d &= \sum_{k=0}^{L-l-1} (\gamma \lambda)^k \delta_{l+k}^d, d \in \{c, r\}. \end{aligned} \quad (52)$$

其中， γ 为折扣因子， λ 为广义优势估计参数，下标old表示采集该批轨迹时的网络参数，轨迹末端的下一状态价值取零。两个优势分量分别经批内标准化后，按偏好加权，并再次标准化，得到策略更新使用的标量优势：

$$A_l^\omega = \mathcal{N}(\omega_c \mathcal{N}(A_l^c) + \omega_r \mathcal{N}(A_l^r)). \quad (53)$$

其中， $\mathcal{N}$ 表示批内标准化。PPO 利用截断代理目标抑制过大的策略更新。记新旧策略的概率比为 $\rho_l(\theta)$ ，其截断代理目标为：

$$\begin{aligned} \rho_l(\theta) &= \frac{\pi_\theta(a_l|s_l)}{\pi_{\theta_{\text{old}}}(a_l|s_l)}, \\ L^{\text{clip}}(\theta) &= \mathbb{E}_l[\min(\rho_l(\theta)A_l^\omega, \text{clip}(\rho_l(\theta), 1 - \varepsilon, 1 + \varepsilon)A_l^\omega)]. \end{aligned} \quad (54)$$

其中， ε 为截断系数。以未标准化的优势构造价值回归目标 $\hat{G}_l^d = A_l^d + V_{\psi_{\text{old}}}^d(s_l)$ ，采用均方误差训练价值网络，同时加入策略熵以鼓励探索。总损失为：

$$\begin{aligned} L(\theta, \psi) &= -L^{\text{clip}}(\theta) + c_V \mathbb{E}_l \left[\frac{1}{2} \sum_{d \in \{c, r\}} (V_\psi^d(s_l) - \hat{G}_l^d)^2 \right] \\ &\quad - c_H \mathbb{E}_l[\mathcal{H}(\pi_\theta(\cdot|s_l))]. \end{aligned} \quad (55)$$

其中， c_V 和 c_H 分别为价值损失系数与熵系数，复合动作的熵为四个分类分布熵之和。每轮利用已采集的同一批轨迹进行多次参数更新，再进入下一轮交互。算法流程见附录 A，训练规模、偏好抽样规则及参数取值见附录 B。

求解新实例时，固定训练得到的网络参数。每个改进步先按最大概率构造一个动作，再通过策略采样生成其余候选动作，经式(43)的修复与验证后，选择 J_ω 最小的候选方案进入下一步；没有有效候选时保留原方案。搜索过程中另行保存历史最优方案，在达到求解预算后返回该方案。

四、数值实验与结果分析

为检验模型与算法的有效性，设置不同规模的危化废弃物收运算例，首先在小规模问题上与精确求解方法比较，考察算法的求解质量；随后扩大问题规模，与启发式策略和遗传算法进行对比；最后将两种规模下训练的模型用于四种规模的未见实例，检验算法的泛化能力。

（第一段简洁，和后面内容重复出现）固定算例实验采用 Python 3.11.5 和 PyTorch 2.5.1+cu121 实现，GPU 为 NVIDIA GeForce RTX 4070 Ti。

（一）实验设置

实验分为固定算例比较与未见实例泛化测试两部分。固定算例包含小规模和大规模各 1 个实例：小规模设置 3 个产废节点、2 类危化废弃物、2 个处理处置节点、3 辆车和 2 个周期；大规模相应为 20 个产废节点、4 类危化废弃物、3 个处理处置节点、8 辆车和 4 个周期。两类算例均考虑持续产废和双端库存结转，期初库存为 0，规划期末库存清零。泛化测试另生成四种规模、每种 50 个独立实例。两部分实验的生成规则与参数分别见附录 B.1 和 B.4，不混合汇总。（精简，策略怎么设置，评价指标是什么）

PPO-Transformer 针对两类规模分别训练一个模型，同一规模下的五组偏好共享模型参数，每组偏好独立推理 3 次。模型训练 20 轮，每轮采集 24 条、每条 24 步的轨迹；求解时搜索 60 步，每步生成 32 个候选动作。GA 在小、大规模下的种群规模分别为 30 和 20，迭代代数分别为 60 和 40，每组偏好运行 1 次。（精简，只说重要参数，不介绍具体算法）评价指标包括经济成本 C 、系统风险 R 、归一化加权目标 J 及求解时间。沿用第三节的加权目标，以同一实例的启发式可行解为归一化参考，成本—风险权重依次取(1,0)、(0.75,0.25)、(0.5,0.5)、(0.25,0.75)和(0,1)， J 越小表示给定偏好下的解质量越好。

（二）小规模问题求解质量比较

为检验所提算法与精确求解结果的差距，在小规模算例上比较 PPO、GA 和 MILP，结果见表 4。启发式初始解作为共同参照，成本为 1384.992，风险为 10.8765（这里放着突兀），各组偏好下均有 $J = 1$ 。（细节移动到第一段）

表 4 小规模算例求解结果（加入灵敏度分析，挑最有意义的参数做）

方法	偏好 (ω_c, ω_r)	成本	风险	J	相对 MILP 差异 (%)	求解时间 (s)
PPO	(1,0)	1138.513	10.7957	0.822036	0.000	
	(0.75,0.25)	1156.515	9.7373	0.850091	1.240	
	(0.5,0.5)	1257.611	7.7118	0.808528	0.000	
	(0.25,0.75)	1909.944	4.6119	0.662776	0.000†	
	(0,1)	2299.022	3.7087	0.340978	2.694†	
GA	(1,0)	1165.515	12.2166	0.841532	2.372	
	(0.75,0.25)	1165.515	9.7517	0.855296	1.860	
	(0.5,0.5)	1165.515	9.7517	0.869059	7.487	

方法	偏好 (ω_c, ω_r)	成本	风险	J	相对 MILP 差异 (%)	求解时间 (s)
MILP	(0.25,0.75)	1377.874	8.8623	0.859826	29.731†	
	(0,1)	1551.230	9.2081	0.846603	154.975†	
	(1,0)	1138.513	10.5697	0.822036		5.86*
	(0.75,0.25)	1138.513	9.7086	0.839681		42.25*
	(0.5,0.5)	1257.611	7.7118	0.808528		160.30*
	(0.25,0.75)	1909.944	4.6119	0.662776		3600.23
	(0,1)	2396.798	3.6114	0.332033		3600.34

注：PPO 表示 PPO-Transformer，成本、风险和 J 均为 3 次推理的均值±样本标准差，方括号内为最佳重启的 J ；其余方法为单次结果。差异按算法 J 相对 MILP 目标值的增幅计算，PPO 采用平均 J 。时间后标注*表示 MILP 已证最优；后两组为限时可行解，故标注†的差异不属于最优性差距。纯风险偏好下，成本仅为返回方案的伴随指标，不代表成本最优。

时间说明：计算时间留空表示缺少与该行一致的逐偏好记录，不以跨偏好均值代填，也不表示时间为 0。PPO 训练耗时不计入求解时间。（表 4 去掉 GA，表 5 加上 GA）

由表 4 可知，MILP 在前三组偏好下均取得最优解，PPO 最佳重启的目标值均在数值精度内达到相应最优值。按 3 次推理均值计算，其最优性差距分别为 0、1.240%和 0，平均为 0.4132%；GA 与启发式策略的平均差距分别为 3.9059%和 21.4745%。在后两组偏好下，MILP 运行至时限仍未证明最优性，PPO 最佳重启与其限时可行目标值在六位小数下相同，平均目标值相对差异分别为 0.000%和 2.694%。因此，所提算法在该小规模算例中获得了较高质量的可行解，但后两组结果不能据此认定为全局最优。从 MILP 计算过程看，前三组偏好分别耗时 5.86 s、42.25 s 和 160.30 s，后两组均达到 3600 s 时限，表明不同偏好下的精确求解难度存在差异。小规模 PPO 模型的一次性训练耗时为 185.028 s，未计入表 4。PPO 最佳结果来自 3 次重启，MILP 则还承担最优性证明；在缺少一致的逐偏好时间记录时，不据此比较二者的求解效率。（注写到文字里，精简，一段话）

（分析解有没有什么特点意义，管理启示）

（三）大规模问题算法性能比较

为考察问题规模扩大后的求解表现，在大规模算例上比较启发式策略、GA 和 PPO-Transformer，结果见表 5。启发式初始解的成本为 29336.011，风险为 2110.0161。该规模未运行 MILP，因此以下比较以算法所得可行解为依据。

表 5 大规模算例求解结果

方法	偏好 (ω_c, ω_r)	成本	风险	J [最佳重启]	相对 GA 降幅 (%)	求解时间 (s)
PPO	(1,0)	16210.584	1025.7687	0.552583	22.66	
	(0.75,0.25)	16440.549	810.5894	0.516357	20.05	

方法	偏好 (ω_c, ω_r)	成本	风险	J [最佳重启]	相对 GA 降幅 (%)	求解时间 (s)
GA	(0.5,0.5)	17324.625	668.8390	0.453771	32.48	
	(0.25,0.75)	21150.130	629.1773	0.403880	40.08	
	(0,1)	36399.345	560.2705	0.265529	54.22	
	(1,0)	20959.942	1271.9923	0.714478		
	(0.75,0.25)	20017.333	1131.4928	0.645822		
	(0.5,0.5)	22727.467	1201.2759	0.672025		
	(0.25,0.75)	24459.733	1309.8811	0.674039		
	(0,1)	26463.505	1223.8862	0.580036		

注：PPO 各项统计口径与表 4 一致，GA 为单次结果。降幅按 PPO 平均 J 相对 GA 的下降比例计算。逐偏好求解时间未记录，相关单元格留空。

由表 5 可知，PPO 在五组偏好下的平均 J 均低于 GA，降幅为 20.05%~54.22%。纯成本偏好下，PPO 的平均成本为 16210.584，低于 GA 的 20959.942，同时风险由 1271.9923 降至 1025.7687。纯风险偏好下，PPO 平均风险为 560.2705，较 GA 降低 54.22%，但平均成本由 26463.505 增加至 36399.345。可见，PPO 在该算例中能够根据目标偏好获得不同的成本—风险组合，而风险水平的进一步降低可能伴随更高的经济投入。

全部 15 次 PPO 推理、5 次 GA 求解和 5 次启发式求解均通过严格可行性检验。大规模 PPO 模型的一次性训练耗时为 375.185 s，五组偏好共享该训练结果，该耗时不计入表 5。由于两种算法的随机重复次数和计算预算不同，且仅测试 1 个大规模实例，上述结果用于说明既定设置下的求解表现，尚不能据此作统计性优劣判断或推断与全局最优解的距离。

（四）泛化能力分析

泛化能力反映训练完成的模型对未见实例的适应程度。为考察训练模型能否在不同问题规模下重复使用，分别在小、大两种规模上训练一个模型，记为 Train-S 和 Train-L，并将其交叉用于四种测试规模，形成 8 个组合，规模设置见表 6。每种测试规模生成 50 个独立实例，各实例设置五组偏好，每组偏好运行 3 个 PPO 求解种子。两份模型各由一个独立训练实例训练，训练与测试实例互不重叠，测试期间冻结参数，不进行微调或检查点重选。GA 在各测试规模上运行同一套基线，两份 PPO 模型共用该基线结果。

表 6 训练规模与测试规模设置

类型	编号	产废节点/品类/设施/车辆 /周期	数量	说明
训练规模	Train-S	3/2/2/3/2	1 份模型	小规模训练模型
训练规模	Train-L	20/4/3/8/4	1 份模型	大规模训练模型

类型	编号	产废节点/品类/设施/车辆 /周期	数量	说明
测试规模	Test-1	3/2/2/3/2	50 个实例	与 Train-S 同规模
测试规模	Test-2	6/2/2/4/3	50 个实例	未见中间规模 1
测试规模	Test-3	10/3/3/5/3	50 个实例	未见中间规模 2
测试规模	Test-4	20/4/3/8/4	50 个实例	与 Train-L 同规模

泛化实验采用统一的生成参数区间，仅改变规模字段，与前述固定算例实验分别统计，具体设置见附录 B.4。结果先在每个“实例—偏好”内对 3 个求解种子取平均，再在实例内等权平均五组偏好，最后以 50 个独立实例计算均值与样本标准差。表 7 报告宏平均目标 $\bar{J}$ ，方括号内为两模型相对差距 L ，即该模型宏平均目标相对于同一测试规模下两模型较小均值的增幅；它不表示与全局最优值的差距，也不等同于严格的泛化损失。

表 7 PPO-Transformer 任务规模泛化结果

训练模型	Test-1	Test-2	Test-3	Test-4
Train-S	0.6286 (20.4506s)	0.5493 (21.9979s)	0.4862 (22.0712s)	0.5523 (30.4859s)
Train-L	0.6374 (22.0188s)	0.5549 (21.9795)	0.4901 (22.2297s)	0.5594 (36.9065s)

注：每格依次列示宏平均目标 $\bar{J}$ （均值±样本标准差）、两模型相对差距 L 和求解时间（s，均值±样本标准差）。各格均包含 50 个完整实例。不同测试规模以各自实例的启发式解归一化，故不同列的目标绝对值不宜直接用于比较问题难度。

由表 7 可知，Train-S 在四种测试规模上的平均目标均略低于 Train-L，后者的相对差距为 0.81%~1.39%。两份模型在未参与训练的中间规模 Test-2、Test-3，以及跨端点规模上均能够完成求解。需要注意，该比较仅涉及两份固定检查点，不能据此认定小规模训练普遍优于大规模训练。为进一步评价其求解效果，表 8 给出可行性及相对 GA 的配对比较结果。

五、结论与管理启示

附录 A PPO-Transformer 算法实现细节

A.1 异构 token 逐维定义

为避免正文被大量符号切断,本附录集中列示七类 token 的有效字段。所有 token 均按“类型编号—有效字段—补零”的顺序封装为 18 维向量;其中,带帽变量表示集合内顺序编号的尺度变换, s_G 、 s_Q 、 s_D 等由实例容量、产生量、距离或事故概率构造。 $C_l/1000$ 、 $R_l/100$ 和 $J_l/1000$ 仅为固定尺度缩放,不表示最大—最小或均值—方差归一化。

token 类型	有效字段	中文含义
全局方案	$[\eta_l, \xi_l, C_l/1000, R_l/100, J_l/1000]$	搜索进度、连续未改进比例,以及固定尺度缩放后的总成本、总风险和加权目标值
成本—风险偏好	$[\omega_c, \omega_r]$	成本偏好权重和风险偏好权重
周期	$[t/t_{max}, G_t/s_G, Q_t/s_Q, IG_t/s_{IG}, ID_t/s_{ID}, P_t/s_P, U_t/ K]$	周期编号、产生量、收运量、产废节点库存、处理处置节点库存、处理量和车辆启用比例
车辆—周期	$[\hat{k}, \hat{t}, u_{(kt)}, D_{(kt)}/s_D, Q_{(kt)}/Q_k, m_{(kt)}/ N_G , A_{(kt)}/s_A]$	车辆与周期编号、启用状态、路线长度、载荷率、任务占比和路线事故概率水平
产废节点—危化 废弃物—周期	$[\hat{i}, \hat{s}, \hat{t}, y_{(nt)}, g_{(nt)}/g_{max}, BG_{(nt)}/s_Q, Q_{(nt)}/s_Q, IG_{(nt)}/s_Q, c_s/c_{max}, r_{(is)}^G/r_{max}^G]$	实体编号、服务状态、产生量、收运前可用量、实际收运量、期末库存、危害后果和产废节点库存风险
处理处置节点— 危化废弃物—周 期	$[\hat{j}, \hat{s}, \hat{t}, a_{(js)}, \bar{p}_{(jst)}/s_Q, R_{(jst)}/s_Q, BD_{(jst)}/s_Q, p_{(jst)}/max(\bar{p}_{(jst)}, 1), ID_{(jst)}/s_Q, c_{(js)}^P/c_{max}^P, r_{(js)}^D/r_{max}^D]$	实体编号、技术匹配、处理能力、接收量、处理前库存、能力利用率、期末库存、处理成本和处理处置节点库存风险
路线弧	$[\hat{k}, \hat{t}, d_{(ab)}^{(cum)}/d_{max}, p_{(ab)}/p_{max}, q_{(ab)}^{(type)}/Q_k, h_{(ab)}^{(type)}/ S]$	车辆与周期编号、弧距离、弧事故概率、累计载荷率和已装载危化废弃物类型占比

A.2 网络、动作与训练参数

策略网络输出一个邻域算子编号和三个操作对象编号。八类邻域算子依次为节点重定位、节点交换、2-opt、处理处置节点替换、服务周期移动、增加提前服务、按危化废弃物类型拆分路线和单节点拆分路线;三个对象编号按算子语义映射为收运任务节点、路线、插入位置、周期、车辆、处理处置节点或危化废弃物类型。

项目	当前实现
token 与编码器	18 维输入; 最多 896 个 token; 嵌入维度 48; 1 层 Transformer 编码器; 4 个注意力头; 前馈维度 96
策略网络输出	8 维算子分类头; 3 个 512 维操作对象分类头
价值网络输出	成本改善价值与风险改善价值, 共 2 维
轨迹采集	24 个并行 episode; 每条轨迹 24 个改进步
PPO 更新	24 轮; $\gamma = 0.95$, $\lambda = 0.90$, $\varepsilon = 0.20$
优化参数	学习率 3×10^{-4} ; 价值损失系数 0.5; 熵系数 0.02
惩罚	无效或确定性修复失败为-0.20; 有效但目标不变为-0.01
训练后搜索	每步综合贪心动作与策略采样动作生成候选方案, 并持续维护历史最优方案

A.3 实现边界

当前实现仅使用填充掩码,不使用动作可行性掩码;约束由邻域操作后的确定性修复与可行性验证处理。固定长度轨迹末端的下一状态价值置零,每个更新轮次对全部样本累积梯

度后执行一次参数更新，且未采用价值函数裁剪、目标 KL 早停或显式 done/truncated 区分。这些设置属于当前工程实现边界，不作为 PPO 基本原理或本文方法创新加以表述。

附录 B 数值实验参数与算例生成规则

B.1 算例生成规则

两类算例均采用合成数据，以 42 为主随机种子，按照 sha256-seed-v1 规则分别派生实例生成、训练和评估种子。节点坐标、单节点—类型—周期产生量、路段事故系数、处理成本及风险系数在表 B1 给定区间内独立均匀抽样，节点间距离按欧氏距离计算。

车辆容量取规划期总产生量除以车辆数后再乘以车辆容量系数；产废节点容量取该节点总产生量与产废端容量系数的乘积，并保证不低于单车容量；处理处置节点容量取规划期总产生量除以设施数后与处置端容量系数的乘积，并保证不低于单车容量。每个“设施—品类—周期”组合的标称处理能力取该品类规划期总产生量与处理能力系数的乘积，再结合技术匹配关系确定有效处理能力。技术匹配关系以 0.85 的概率生成，并确保每类废物至少有一个可处理设施；品类兼容概率为 1，初始库存为 0，规划期末两端库存清零。

表 B1 算例规模与模型参数

参数	小规模算例	大规模算例
产废节点数/废物类型数/处理处置节点数	3/2/2	20/4/3
车辆数/周期数	3/2	8/4
单节点—类型—周期产生量区间	[0.5, 2.0]	[0.2, 1.2]
坐标区间	[0, 100]	[0, 200]
路段事故概率区间	[0.0005, 0.003]	[0.0005, 0.004]
车辆容量系数 α_K	1.8	1.6
产废端库存容量系数 α_G	2.5	3.0
处理处置端库存容量系数 α_D	3.0	3.5
处理能力系数 α_P	2.0	2.5

参数	小规模算例	大规模算例
车辆固定启用成本	50	50
单位距离运输成本	3	3
处理成本区间	[4, 20]	[5, 12]
废物后果系数区间	[1, 4]	[1, 5]
产废端库存风险系数区间	[0.2, 1.0]	[0.2, 1.2]
处理处置端库存风险系数区间	[0.1, 0.8]	[0.1, 1.0]
异类废物共载风险系数区间	[0.05, 0.5]	[0.05, 0.6]
废物兼容概率/技术匹配概率	1.00/0.85	1.00/0.85
最小收运量/期末库存清零	0.001/是	0.001/是

B.2 算法训练与求解参数

小规模和大规模分别训练一个 PPO 模型。训练时，两个端点偏好的抽取概率均为 0.1，其余 80%的偏好样本由 Beta(0.5,0.5)分布生成。训练完成后固定模型参数，分别对五组预设偏好独立重启 3 次。训练轮次与每轮策略更新次数为不同参数，前者为 20，后者为 24，具体设置见表 B2。GA 及 MILP 参数见表 B3，网络参数见表 B4。

表 B2 PPO-Transformer 训练与推理参数

方法	参数	取值	参数	取值
PPO	训练迭代轮次	20	每轮并行 episode 数	24
PPO	每个 episode 步数	24	每轮策略更新次数	24
PPO	学习率	0.0003	折扣因子 γ	0.95
PPO	GAE 参数 λ	0.90	PPO 截断系数	0.20
PPO	熵系数	0.02	价值损失系数	0.50

方法	参数	取值	参数	取值
PPO	修复失败惩罚	0.20	无变化动作惩罚	0.01
PPO	单次推理搜索步数	60	每步候选动作数	32
PPO	每种偏好推理重启数	3	两个端点偏好抽取概率	各 0.10
PPO	Beta 分布参数	(0.5,0.5)	主随机种子	42

表 B3 GA 与 MILP 求解参数

方法	参数	小规模算例	大规模算例
GA	种群规模	30	20
GA	迭代代数	60	40
GA	交叉率	0.85	0.90
GA	变异率	0.20	0.25
GA	精英保留数	2	4
GA	锦标赛规模	3	3
MILP	单个偏好求解时限	3600 s	未运行

表 B4 Transformer 网络结构参数

方法	参数	取值
PPO	网络类型	Full Transformer
PPO	嵌入维度	48
PPO	编码器层数	1
PPO	注意力头数	4
PPO	前馈网络维度	96
PPO	Dropout	0

方法	参数	取值
PPO	最大 token 数	896
PPO	邻域算子数量	8
PPO	动作对象槽位数	512
PPO	偏好 token	使用
PPO	在全局向量中嵌入偏好	否
PPO	路径弧 token	使用
PPO	处理处置节点 token	使用

B.4 泛化实验设置与冻结模型

泛化测试采用统一的生成规则，仅按表 6 改变节点、品类、设施、车辆和周期数量。单节点—品类—周期产生量取[0.5,2.0]，坐标取[0,100]，路段事故系数取[0.0005,0.003]，处理成本取[4.0,20.0]；车辆容量、产废端容量、处置端容量和处理能力系数分别为 1.8、2.5、3.0 和 2.0。废物后果系数取[1.0,4.0]，产废端库存风险系数取[0.2,1.0]，处置端库存风险系数取[0.1,0.8]，共载风险系数取[0.05,0.5]。车辆固定成本为 50.0，单位距离成本为 3.0，兼容概率为 1.0，技术可用概率为 0.85，期末库存清零。根种子为 42，种子派生规则为 sha256-seed-v1。

表 B5 泛化实验冻结模型与训练耗时

方法	训练模型	训练实例 seed	训练 seed	检查点	训练耗时 (s)
PPO	Train-S	4247481937	3280000028	models/ small_ model.pt	778.809
PPO	Train-L	4057074506	3416884852	models/ large_ model.pt	1233.161

两份训练实例与 200 个测试实例的种子及内容哈希均无交集。模型采用 48 维嵌入、1 层编码器、4 个注意力头和 96 维前馈网络，训练 20 轮，每轮 24 条轨迹、每条 24 步；推理

时搜索 60 步，每步生成 32 个候选动作。GA 在 Test-1 和 Test-2 采用种群 30、60 代，在 Test-3 和 Test-4 采用种群 20、40 代，每个实例—偏好均运行 3 个求解种子。PPO 批次使用 4 或 8 个工作进程，GA 使用 16 个工作进程，因此所报告时间不代表隔离运行条件下的纯算法速度。

补充实验记录中 6000 个 PPO、3000 个 GA、500 个启发式和 250 个 MILP 运行单元均已完成，完整性验证通过，缺失、技术失败和完整性错误均为 0。补充实验 MILP 采用 180 s 时限，仅用于 Test-1 主测试，不作为表 7 两模型相对差距的基准，亦不与表 4 的 3600 s 固定算例结果合并。按数值容差 0.000000001 判定 PPO 与 GA 的配对结果是否持平。

参考文献

- [1] ALUMUR S, KARA B Y. A new model for the hazardous waste location-routing problem[J]. *Computers & Operations Research*, 2007, 34(5): 1406-1423.
- [2] SHEU J B. A coordinated reverse logistics system for regional management of multi-source hazardous wastes[J]. *Computers & Operations Research*, 2007, 34(5): 1442-1462.
- [3] ELBEK M, WØHLK S. A variable neighborhood search for the multi-period collection of recyclable materials[J]. *European Journal of Operational Research*, 2016, 249(2): 540-550.
- [4] PAREDES-BELMAR G, BRONFMAN A, MARIANOV V, et al. Hazardous materials collection with multiple-product loading[J]. *Journal of Cleaner Production*, 2017, 141: 909-919.
- [5] RABBANI M, HEIDARI R, FARROKHI-ASL H, et al. Using metaheuristic algorithms to solve a multi-objective industrial hazardous waste location-routing problem considering incompatible waste types[J]. *Journal of Cleaner Production*, 2018, 170: 227-241.
- [6] RABBANI M, HEIDARI R, YAZDANPARAST R. A stochastic multi-period industrial hazardous waste location-routing problem: Integrating NSGA-II and Monte Carlo simulation[J]. *European Journal of Operational Research*, 2019, 272(3): 945-961.
- [7] MA H, LI X. Multi-period hazardous waste collection planning with consideration of risk stability[J]. *Journal of Industrial & Management Optimization*, 2021, 17(1): 393-408.
- [8] WU W, MA J, LIU R, et al. Multi-class hazmat distribution network design with inventory and superimposed risks[J]. *Transportation Research Part E: Logistics and Transportation Review*, 2022, 161: 102693.
- [9] BENGIO Y, LODI A, PROUVOST A. Machine learning for combinatorial optimization: A methodological tour d'horizon[J]. *European Journal of Operational Research*, 2021, 290(2): 405-421.
- [10] MAZYAVKINA N, SVIRIDOV S, IVANOV S, et al. Reinforcement learning for combinatorial optimization: A survey[J]. *Computers & Operations Research*, 2021, 134: 105400.
- [11] YAN Y, CHOW A H F, HO C P, et al. Reinforcement learning for logistics and supply chain management: Methodologies, state of the art, and future opportunities[J]. *Transportation Research Part E: Logistics and Transportation Review*, 2022, 162: 102712.
- [12] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[EB/OL]. (2017-07-20)[2026-08-25]. <https://arxiv.org/abs/1707.06347>.
- [13] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//*Advances in Neural Information Processing Systems*. Red Hook: Curran Associates, 2017, 30: 5998-6008.
- [14] WU Y, SONG W, CAO Z, et al. Learning improvement heuristics for solving routing problems[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2022, 33(9): 5057-5069.
- [15] MA Y, LI J, CAO Z, et al. Learning to iteratively solve routing problems with dual-aspect collaborative transformer[C]//*Advances in Neural Information Processing Systems*. Red Hook: Curran Associates, 2021, 34: 11096-11107.
- [16] LIN X, YANG Z, ZHANG Q. Pareto set learning for neural multi-objective combinatorial optimization[C]//*International Conference on Learning Representations*. 2022.