



系统工程理论与实践
Systems Engineering-Theory & Practice
ISSN 1000-6788,CN 11-2267/N

《系统工程理论与实践》网络首发论文

题目：众包模式下基于并行生成策略的强化学习路径规划模型
作者：向传凯，吴志彬，徐玖平
收稿日期：2025-01-07
网络首发日期：2026-01-07
引用格式：向传凯，吴志彬，徐玖平. 众包模式下基于并行生成策略的强化学习路径规划模型[J/OL]. 系统工程理论与实践.
<https://link.cnki.net/urlid/11.2267.N.20260107.1028.006>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

众包模式下基于并行生成策略的强化学习路径规划模型

向传凯^{1,2,3}, 吴志彬², 徐玖平²

(1. 西南交通大学交通运输与物流学院, 成都 611756, 2. 四川大学商学院, 成都 610065, 3. 香港城市大学数据科学系, 香港 999077)

摘要 本文研究了众包模式下的带取送货约束的车辆路径规划问题。根据问题特点建立了平台视角下的马尔科夫决策模型, 并提出了一种基于 Transformer 的深度强化学习算法求解所提问题。为了解决现有“串行生成”的解码方式难以适用于众包背景下的多车辆路径规划问题, 通过引入车辆轮换神经网络, 重构了 Transformer 神经网络的解码过程, 实现并行地为多个众包车辆规划路径。本文通过仿真模拟和真实数据验证了所提算法的有效性和优越性。实验结果表明: 所提算法能够在小规模问题上取得接近精确解, 在中大规模问题上的表现优于传统元启发式算法和现有智能算法; 基于车辆轮换神经网络的“并行生成”策略带来的效果提升明显; 所提算法具有良好的泛化能力, 具备迁移至真实应用场景的潜力。

关键词 众包物流; 取送货问题; 多车辆路径规划; 深度强化学习

Reinforcement learning-based method with parallel generation strategy for crowdshipping

XIANG Chuankai^{1,2,3}, WU Zhibin², XU Jiuping²

(1. Southwest Jiaotong University, School of Transport and Logistics, Chengdu, China, 611756, 2. Sichuan University, Business School, Chengdu, China, 610065, 3. City University of HongKong, Department of Data Science, HongKong, China, 999077)

Abstract This study investigates the vehicle routing problem with pickup and delivery constraints of crowdshipping. A Markov decision process model is established from the platform's perspective, and a Transformer-based deep reinforcement learning algorithm is proposed to solve the problem. To address the limitations of the traditional sequential decoding approach, which is challenging to apply to multi-vehicle routing problems in crowdshipping, a vehicle rotation neural network is introduced to reconstruct the decoding process of the Transformer neural network. The effectiveness and superiority of the proposed algorithm are verified through simulation and real-world data. Experimental results demonstrate that the algorithm achieves near-optimal solutions for small-scale problems and outperforms traditional metaheuristic algorithms and existing intelligent algorithms for medium- and large-scale problems. The “parallel generation” strategy based on the vehicle rotation neural network significantly enhances performance. Furthermore, the proposed algorithm exhibits strong generalization capabilities, making it promising for real-world applications.

收稿日期: 2025-01-07

作者简介: 向传凯 (1995-), 男, 四川广安人, 助理教授, 研究方向: 交通运输, 众包物流, 数据科学 E-mail: 731234199@qq.com; 吴志彬 (1982-), 男, 四川资中人, 教授, 博士生导师, 研究方向: 决策理论与方法, 机器学习及应用, E-mail: zhibinwu@scu.edu.cn; 徐玖平 (1962-), 男, 重庆人, 教授, 国家杰出青年基金获得者, 长江学者, 博士生导师, 研究方向: 决策理论, 管理科学等, E-mail: xujiuping@scu.edu.cn.

基金项目: 国家自然科学基金资助项目 (72371175); 中央高校基本科研业务费专项资金项目 (2024ZY-SXT1)

Foundation item: National Natural Science Foundation of China (72371175); Fundamental Research Funds for the Central Universities (2024ZY-SXT1)

Keywords Crowd logistics; Pickup and delivery problem; Multi-vehicle routing problem; Deep reinforcement learning

1 引言

新的商业模式催生新的问题与挑战。在传统的物流模式中,供需关系相对稳定,企业能够依赖预先规划好的运输路线进行重复性运营。然而,在众包物流模式中,可重复利用的运输路线则可能较少,更多则是需要“即时规划”。众包物流的按需服务模式使运输供需具有较高的随机性和即时性。在这种模式下,每当有新的众包车辆或运输需求加入系统时,配送平台就需要实时地更新众包车辆和运输需求的匹配方案,并为众包车辆规划取送货路径。“即时规划”对规划算法的计算效率提出了极高的要求^[1]。尽管整数规划算法和启发式算法在传统物流模式已发展相对成熟,能够得到理论上的精确解,但由于其计算时间较长,因此无法很好地适用于众包模式下的路径规划问题^[1]。尤其在真实应用场景中,供需状况和运输条件变化更加迅速,传统算法则愈发力不从心。因此,探索新的技术,开发更为高效和灵活的规划算法,对保障众包物流的服务效率与质量具有重要的价值和意义。

为了适应众包物流运营过程中的快速决策,本文提出一种基于 Transformer 神经网络的深度强化学习的算法。基于 Transformer 神经网络的深度强化学习算法,本质上是逐步预测车辆的下一个访问节点,从而为车辆生成完整路径。现有 Transformer 算法采用的是“串行生成”模式,即先为前一车辆生成完整路径后,然后再为后一车辆生成路径。然而“串行生成”模式难以适用于“在线”运营的众包物流。例如,假设现有众包车辆 a 和 b 和若干已知的运输任务,在某时刻新到一运输任务 n ,任务 n 与车辆 a 更加匹配,而此时如果算法已完成车辆 a 的路径生成,那么新到任务 n 只能推荐给次优的车辆 b 。为了解决该问题,本文引入一种“并行生成”的路径生成策略,在每个时间步轮换规划车辆,使算法能够并行地为所有车辆生成路径。此外,为了找到自适应的轮换策略,本文设计了车辆轮换神经网络,在马尔科夫决策过程中对轮换策略进行动态学习。因此,本研究的主要贡献可以概括为以下几点:

1) 考虑了一种在众包模式下的取送货路径规划问题,相比传统取送货问题,融入了众包车辆既定起点与终点的路径约束,重点刻画顺路性特征,提升了模型对众包实际运营场景的适应性。

2) 提出了一种针对众包背景下多车辆的深度强化学习算法。所提算法通过车辆轮换神经网络重构 Transformer 的解码过程,实现并行地为多个众包车辆规划路径,相比“串行生成”模式,有效提高了算法的性能和可拓展性。

3) 通过与现有的精确算法、启发式算法以及学习类智能算法的比较分析,本文验证了所提算法在求解质量和速度方面的优势。通过消融实验、泛化能力测试以及在真实运营数据上的验证,进一步证明了算法的稳健性和实用性。最后基于实验结果给出了管理启示。

2 文献综述

已有关于众包物流路径规划的研究中主要集中于基于精确算法和启发式算法的模型求解,采用学习算法的研究相对较少。为系统梳理相关研究进展,本文将从基于精确算法的众包路径规划、基于启发式算法的众包路径规划,以及基于学习算法的车辆路径规划研究三个方面进行综述。

2.1 基于精确算法的众包路径规划

精确算法通过构建严格的数学模型,目的是在有限时间内找到问题的最优解。针对众包物流背景下的路径规划问题,Arslan 等^[2]通过设计滚动时间框架,并在滚动框架中引入基于整数规划的精确求解算法,优化众包配送员和专用车辆的实时匹配策略。Behrend 等^[3]考虑了将物品共享与众包物流相结合的一种众包模式,提出基于集合打包的精确算法,优化配送员的容量利用和路径规划,证明高容量配送员能够显著提高运输效率。Han 和 Cheng^[4]研究单个配送员的任务选择问题,通过分支剪切方法高效生成约束条件以实现全局最优,证明其在降低额外行程时间和碳排放方面具有重要价值。Torres 等^[5]提出开放型车辆路径问题模型,通过分支定价算法解决配送请求随机性问题,发现远离中心仓库的配送员可显著降低成本。Mousavi 等^[6]通过分支剪切和裁剪投影算法,在移动中继点和随机配送员可用性条件

下优化任务分配, 并降低配送失败风险。

随后, Torres 等^[7] 进一步扩展到随机供应和时间窗约束的场景, 开发创新的列生成方法, 显著提高了随机优化方案的效益。Nieto-Isaza 等^[8] 探索了支持小型中继站的众包物流, 通过 Benders 分解方法优化中继站选址和需求分配。Boysen 等^[9] 采用 Benders 分解方法, 优化配送中心员工的众包任务匹配, 提高配送效率并保障最低收益。Pugliese 等^[10] 利用 Benders 分解和列行生成方法, 针对不确定旅行时间和罚款成本设计鲁棒优化策略, 减少未完成任务的影响。Su 等^[11] 针对包含众包竞标与中转的取送货问题, 提出了基于路径与弧的双重建模方法, 并开发了结合分支定价剪切的精确算法。Stokkink 等^[12] 研究允许中转的众包物流系统, 通过列生成和行生成结合的算法, 优化配送员协作与中转操作。

从以上研究可以看出, 尽管采用精确算法求解众包物流的路径规划问题能够得到最优解, 但往往需要根据问题特性对算法进行深度化的定制。此外, 随着问题规模的增加, 精确算法的计算成本呈指数级增长, 难以适应真实场景中的大规模问题。

2.2 基于启发式算法的众包路径规划

启发式算法相比精确算法具有计算速度和计算规模上的优势, 但启发式算法由于对解的搜索并不完全, 因此容易陷入局部最优。针对路径规划与任务分配优化, Kafle 等^[13] 采用禁忌搜索优化城市包裹配送中的中转点和路径规划, 显著减少了车辆行驶里程和成本。周林等^[14] 针对众包车辆的协同配送优化问题, 提出了支持多任务捎带的协同配送模型, 并设计混合分散搜索算法进行求解, 仿真实验验证了模型和算法的有效性。Macrina 等^[15] 通过可变邻域搜索算法优化带中转点的任务分配, 有效降低了配送成本并在较短时间内解决大规模实例。葛显龙等^[16] 在考虑不同交付方式的场景下, 构建了混合整数规划模型, 使用自适应大邻域搜索算法优化路径, 实验显示该方法在城市末端配送中可实现 18.1% 的成本节约。Elsokkary 等^[17] 结合 k-medoids 聚类、禁忌搜索和遗传算法优化最后一公里配送任务分配, 提升了任务完成率和服务质量。在智能优化领域, Hamid 等^[18] 开发了一种结合遗传算法与粒子群优化的超启发式方法, 优化多模式运输中的时间敏感任务; Longo^[19] 通过记忆式遗传算法优化众包配送路径, 显著缩短了运行时间。Zheng 等^[20] 结合分解策略与迭代贪婪算法解决不确定外卖配送中的订单分配问题, 显著降低了风险与计算时间。Liang 等^[21] 结合混合遗传算法和插入算法优化动态调度问题, 提高了利润和任务匹配率。周煜丰等^[22] 研究了需求可拆分的雇佣和众包车辆协同运输问题, 提出上下两层遗传算法结合支持向量机模型辅助搜索优化路径规划, 实验结果表明该方法能够有效降低企业运营成本。

通过对现有文献的调研可以发现, 学者们主要采用邻域搜索算法、进化算法、以及粒子群等算法对众包路径问题进行求解。启发式算法的引入有效提高了问题的求解规模, 但串行迭代的工作模式也进一步限制了这些算法在动态环境中的表现。

2.3 基于学习算法的车辆路径规划

近年来, 结合深度神经网络的强化学习算法在组合优化领域表现出众, 完成训练的智能体能够在极短的时间内给出可行解, 目前已有学者对其在路径规划领域的应用开展了初步研究。Vinyals 等^[23] 通过监督学习对指针神经网络进行训练, 这是将深度学习应用于组合优化问题的早期尝试之一。然而监督学习需要依赖大量的标记数据, 这在实际应用中往往难以获得。此外监督学习所训练的模型, 在性能方面通常受限于训练数据的质量。为了克服这些限制, Bello 等^[24] 将指针神经网络嵌入到强化学习框架中, 通过与环境的交互来学习策略。这种方法使得模型能够自主地探索并学习到更优的解决方案, 从而在性能上超越了监督学习。Nazari 等^[25] 进一步简化了 Bello 等^[24] 提出的模型, 专注于解决路径规划问题。与传统启发式算法相比, 简化后的模型在求解质量和速度上都具有显著优势。Kool 等^[4] 首次通过强化学习对 Transformer 网络进行训练, 进一步提升了求解质量。

在后续的研究中, 学者将这类算法做了相应的推广和应用, 如 James 等^[27] 和 Li 等^[28] 分别将基于指针神经网络和 Transformer 神经网络的强化学习算法应用在取送货问题中。James 等^[27] 通过在智能体的奖励函数中引入惩罚项来实现对取货和送货节点访问次序的“软控制”。而 Li 等^[28] 则采用了掩码技术对未取货的送货节点进行遮掩, 实现了对访问次序的“硬控制”。Guo 等^[29] 引入维度缩减技术

和门控机制对 Transformer 神经网络加以改进,使之适用于时间依赖路径规划问题. Fan 等^[30] 使用基于 Transformer 神经网络的强化学习求解城市中无人机的路径规划问题,较大的提高了求解速度. 此外,也有学者将这类深度强化学习算法应用在具有较大求解规模的路径规划相关问题,如 Zhang 等^[31] 将 Transformer 神经网络引入两阶段求解框架中,用以求解大规模的取送货问题. Ye 等^[32] 将 Transformer 神经网络引入“全局-局部”优化框架中,用以求解大规模的路径规划相关问题.

基于 Transformer 神经网络的深度强化学习在路径规划问题已经得到一定的发展,并且在求解质量和求解速度均有提升. 这些研究为解决众包物流中的路径规划相关问题提供了新的视角和工具.

3 众包模式下多车辆取送货问题

在众包模式下的取送货路径规划决策问题 (Pickup and Delivery Problem with Crowd-shipper, PDPC) 中, 众包物流平台作为第三方运输机构为客户提供小件包裹代送服务, 其主要运力来源为众包车辆. 顾客通过线上平台发布运输任务, 众包车辆接单后, 从其起点出发前往取货地取货, 随后运输该任务. 众包车辆可以同时运输多个任务, 在完成所有运输任务后, 众包车辆前往其原定目的地. 此类问题的特点在于运输任务和众包车辆均有自己独立的起点和终点, 在路径规划过程中需要考虑任务与众包车辆的顺路程度, 其运营模式如图 1 所示.



图 1 众包模式下取送货问题示意图

假设, P 为当前系统中运输任务的集合, 任务取货节点的集合为 O^1 , 任务送货节点的集合为 D^1 , 运输任务 $p, p \in P$ 的取货节点为 $o_p^1, o_p^1 \in O^1$, 送货节点为 $d_p^1, d_p^1 \in D^1$. V 为众包车辆的集合, 众包车辆的起点集合为 O^2 , 终点集合为 D^2 , 因此众包车辆的起点节点可表示为 $o_v^2, o_v^2 \in O^2$, 车辆终点节点可表示为 $d_v^2, d_v^2 \in D^2$. 此外, N 为所有节点的集合, 表示为 $N = O^1 \cup O^2 \cup D^1 \cup D^2$, N^1 为与任务有关节点 (任务的起点和终点) 的集合, 表示为 $N^1 = O^1 \cup D^1$, N^2 为与众包车辆有关的节点 (众包车辆的起点与终点) 的集合, 表示为 $N^2 = O^2 \cup D^2$. 令 $l(i, j)$ 为两节点之间的距离函数, $x_{i,j}^v$ 为模型的决策变量, $x_{i,j}^v = 1$ 表示车辆 v 从节点 i 出发, 访问节点 j , $x_{i,j}^v = 0$ 表示车辆 v 不经过由 i 到 j 的路径. B_i 为连续变量, 表示车辆到达节点 i 的时刻, 其中 $i \in N^1$. 假设 $t_{i,j}$ 表示节点 i 到节点 j 所需要的时间. PDPC 可建模为整数规划模型, 详见附录 A.

平台的主要任务是匹配当前系统中的运输任务和众包车辆, 并规划路径, 其规划目标为最小化平台运输成本. 基于 PDPC 问题的特性, 本文做出如下假设: 所有运输任务均有独立的取货节点和送货节点, 且不重合. 所有众包车辆均有独立的起点和终点, 并互不重合. 鉴于本文的研究重点在于算法改进, 分析的核心在于验证所提出的并行生成策略在众包模式下取送货问题中的适用性. 为突出算法性能分析, 本文对众包物流模型进行了简化处理, 未考虑车辆运力限制与服务时间窗的约束, 此类设定亦见于

文献 [30, 43]. 此外, 众包运输任务主要涉及小件包裹^[11], 且包裹可暂存于临时快递柜中, 因此放宽运力与时间窗限制在实际应用中亦具一定合理性与可行性.

4 基于深度强化学习的求解算法

针对所提 PDPC 问题, 本文基于深度强化学习算法设计了求解算法. 求解算法的整体框架如图 2 所示 (求解算法的伪代码见附录 B). 该框架包含嵌入神经网络、车辆轮换神经网络、以及路径生成神经网络三大主体神经网络. 首先使用嵌入神经网络 (4.2 节) 将环境信息嵌入成神经网络可处理的高维向量, 然后将嵌入后的状态信息输入车辆轮换神经网络 (4.3 节) 和路径生成神经网络 (4.4 节), 车辆轮换神经网络根据状态信息确定当前的规划车辆, 路径生成神经网络为当前车辆确定下一个访问节点. 然后算法基于模型做出的动作计算奖励和算法的 Loss 值, 并更新神经网络的参数. 本节的内容将详细介绍求解算法中所涉及的马尔科夫决策模型、嵌入神经网络、车辆轮换神经网络、路径生成神经网络的计算过程.




图 2 深度强化学习求解框架

4.1 平台视角下的马尔科夫决策模型

在每一轮决策过程中, 众包平台需要根据当前环境信息确定当前规划车辆, 并为该车辆决策下一个访问节点, 在此轮决策过程结束后, 环境信息会根据决策结果发生变化, 并进入下一轮决策过程. 本文将上述决策链建模为马尔科夫决策模型. 以下内容将详细介绍马尔科夫决策模型的状态、动作、状态转移函数、以及奖励函数.

1) 状态: 针对 PDPC, 环境在 t 时刻的状态集合定义为 $s_t = (P_t, V_t)$, 其中 P_t 表示运输任务集合在 t 时间步的状态, 可由任务池中剩余任务的取货节点表示, 即 $P_t = \{n_1, n_2, \dots, n_{|O^1|-t}\}$, 其中 $n_i \in O^1$; V_t 表示所有众包车辆在 t 时间步的状态集合, v_t 表示每个车辆在 t 时间步的状态集合, 具体可以表示为 $v_t = (G_{v,t}, L_{v,t}, N'_{v,t}, w_{v,t})$, 其中 $G_{v,t}$ 表示车辆 v 在时间步 t 已被规划的路径, $L_{v,t}$ 表示已被规划路径的行驶距离, $N'_{v,t}$ 是指车辆 v 目前尚未完成配送的送货点集合, $w_{v,t}$ 表示车辆 v 当前已完成的任务数量.

2) 动作: 动作 $a_t \in A$ 表示强化学习在时间步 t 做出的动作, 其中 $a_t = (v, n_i), v \in V, n_i \in N^1$, 是指平台在时间步 t 为众包车辆 v 指定的下一个访问节点为 n_i . 平台为该众包车辆指定的下一访问节点, 需满足问题约束, 即滤除不符合当前规划车辆约束的节点, 如已被自己取货的节点、已被其他车辆取货的节点、其他车辆已取货的送货节点, 自己未完成取货的送货节点.

3) 状态转移: 平台做出决策动作 a_t 后, 环境的状态会发生变化. 其中任务集合的状态变化方向如

下:

$$P_{t+1} = \begin{cases} P_t \setminus \{n_i\}, & n_i \in N'_{v,t} \\ P_t, & n_i \notin N'_{v,t} \end{cases} \quad (1)$$

众包车辆的状态转移方向如下:

$$G_{z,t+1} = \begin{cases} G_{z,t} \cup \{n_i\}, & \text{如果 } z = v, \\ G_{z,t}, & \text{否则.} \end{cases} \quad (2)$$

$$L_{z,t+1} = \begin{cases} L_{z,t} + l(n_{z,t}, n_i), & \text{如果 } z = v, \\ L_{z,t}, & \text{否则.} \end{cases} \quad (3)$$

$$N'_{z,t+1} = \begin{cases} N'_{z,t} \cup \{n_i\}, & \text{如果 } z = v, n_i \notin N'_{v,t}, \\ N'_{z,t} \setminus \{n_i\}, & \text{如果 } z = v, n_i \in N'_{v,t}, \\ N'_{z,t}, & \text{否则.} \end{cases} \quad (4)$$

$$w_{z,t+1} = \begin{cases} w_{z,t} + 1, & \text{如果 } z = v, n_i \in N'_{v,t}, \\ w_{z,t}, & \text{否则.} \end{cases} \quad (5)$$

(14) 式中 $n_{z,t}$ 表示 $G_{z,t}$ 中的最后一个节点.

4) 奖励函数: 为了引导模型学习能够使运输成本降低的策略, 本文将平台负的成本作为奖励函数. 在此奖励函数下, 成本越高, 模型得到的奖励越少. 在众包物流中, 若仅是粗略地考虑总成本, 则有可能使得部分众包车辆被分配的任务过多或过少, 无法考虑众包车辆自身的需求. 因此, 本文将具有最大成本的众包车辆的负的成本值作为智能体的奖励函数, 以此避免可能出现的上述问题, 奖励函数见式 (6),

$$R = -\max_{v \in V} \left(\|n_{\pi[v][1]}, n_{o_v^2}\|_2 + \|n_{\pi[v][|\pi[v]|]}, n_{d_v^2}\|_2 + \sum_{t=1}^{|\pi[v]|-1} \|n_{\pi[v][t]}, n_{\pi[v][t+1]}\|_2 \right) \quad (6)$$

其中, $\|n_{\pi[v][1]}, n_{o_v^2}\|_2$ 表示车辆从其起点出发到第一个取货点的距离, $\|n_{\pi[v][|\pi[v]|]}, n_{d_v^2}\|_2$ 表示车辆送完最后一个包裹后前往其终点的距离, $\sum_{t=1}^{|\pi[v]|-1} \|n_{\pi[v][t]}, n_{\pi[v][t+1]}\|_2$ 表示除去起点和终点的剩余路径的距离, $\pi[v][t]$ 表示车辆 v 路径中的第 t 个节点.

4.2 嵌入神经网络

由于真实世界的信息难以被神经网络直接感知, 因此需要设计一个嵌入神经网络对众包任务和众包车辆的特征信息进行嵌入.

4.2.1 初始嵌入层

PDPC 中有四类节点, 众包任务的取货节点和送货节点, 众包车辆的起点和终点, 每类节点都有其独有的特征. 本文设计了一个初始嵌入网络用以加工上述节点的特征信息. 运输任务的送货节点的特征信息包含地理坐标 $(x_{d_p^1}, y_{d_p^1})$ 和该送货节点到达各众包车辆起点和终点的距离 $l(n_{d_p^1}, n_{o_v^2}, n_{d_v^2})$, $v = 1, 2, \dots, |V|$, 由此, 送货节点的特征信息可以表示为:

$$\tilde{n}_{d_p^1} = [x_{d_p^1}; y_{d_p^1}; l(n_{d_p^1}, n_{o_1^2}, n_{d_1^2}); \dots; l(n_{d_p^1}, n_{o_{|V|}^2}, n_{d_{|V|}^2})] \quad (7)$$

取货节点的特征信息与送货节点的特征信息略有不同, 这是因为智能体在考虑某个取货节点时, 需同时考虑与该取货节点相匹配的送货节点的信息, 因此任务 p 的取货节点的特征信息可以表示为:

$$\tilde{n}_{o_p^1} = [x_{o_p^1}; y_{o_p^1}; \tilde{n}_{d_p^1}; l(n_{o_p^1}, n_{o_1^2}, n_{d_1^2}); \dots; l(n_{o_p^1}, n_{o_{|V|}^2}, n_{d_{|V|}^2})] \quad (8)$$

众包车辆的起点和终点的特征信息相对简单, 只需要考虑其坐标信息即可, 因此众包车辆的起点和终点的特征信息可以分别表示为: $\tilde{\mathbf{n}}_{o_v} = [x_{o_v}^2; y_{o_v}^2]$, $\tilde{\mathbf{n}}_{d_v} = [x_{d_v}^2; y_{d_v}^2]$. 本节所用的“ $[\cdot]$ ”均表示向量的粘接操作.

本文使用线性投影网络对上述各节点的特征信息进行升维投影, 以便接入基于多头注意力机制的编码神经网络. 各类节点的线性投影操作表示如下: 任务取货点的线性投影, $\mathbf{h}_{o_p}^0 = \mathbf{W}^1 \cdot \tilde{\mathbf{n}}_{o_p} + \mathbf{b}^1$; 任务送货点的线性投影, $\mathbf{h}_{d_p}^0 = \mathbf{W}^2 \cdot \tilde{\mathbf{n}}_{d_p} + \mathbf{b}^2$; 车辆起点的线性投影, $\mathbf{h}_{o_v}^0 = \mathbf{W}^3 \cdot \tilde{\mathbf{n}}_{o_v} + \mathbf{b}^3$; 车辆终点的线性投影: $\mathbf{h}_{d_v}^0 = \mathbf{W}^4 \cdot \tilde{\mathbf{n}}_{d_v} + \mathbf{b}^4$. 其中, $\mathbf{W}$ 为参数矩阵, $\mathbf{b}$ 为偏置向量, 上标表示类别, $\mathbf{W}^1$ 的维度为 $\dim \times (|V| + 2)$, $\mathbf{W}^2$ 的维度为 $\dim \times (2|V| + 4)$, $\mathbf{W}^3$ 和 $\mathbf{W}^4$ 的维度为 $\dim \times 2$. 线性投影结果的上标 0 表示处于整个神经网络的第 0 层, $\dim$ 表示神经网络的嵌入维度.

4.2.2 基于多头注意力机制的编码神经网络

与文献 [29] 类似, 本文采用标准的多头注意力机制作为节点特征的编码器. 编码器由 $C \times Z$ 注意力层堆叠而成, C 表示编码器中注意力的层数, Z 表示每层注意力层的注意力头的数量. 注意力层之间由一个前馈神经网络残差连接. 多头注意力机制的核心能力在于能够切分特征信息向量, 并在多个子空间内并行计算, 最后将计算结果重新整合, 从而观察到更加丰富的内在信息.

本文设计的多头注意力机制一共有 Z 个注意力头, 意味着节点信息向量将切分成 Z 份, 并在各自的子空间中计算. 在某个子空间中, 一个节点与其他节点的配合度 (Compatibility) 取决于该节点的查询向量 (Query) 和其他节点的键向量 (Key). 在 PDPC 中有四类节点, 节点总数为 $m = |N|$. 任意两个节点的配合度 $u_{i,j}$ 计算如下:

$$u_{i,j} = \frac{\mathbf{q}_i^T \cdot \mathbf{k}_j}{\sqrt{\dim_e}}, \quad i, j = 1, 2, \dots, m \quad (9)$$

其中 $\mathbf{k}_j = \mathbf{W}^K \mathbf{h}_j^0$ 表示节点 j 的 Key, $\mathbf{q}_i = \mathbf{W}^Q \mathbf{h}_i^0$ 表示节点 i 的 Query, $\mathbf{W}^K$ 和 $\mathbf{W}^Q$ 为参数矩阵, 维度为 $\dim \times \dim_e$, $\dim_e = \frac{\dim}{Z}$ 代表节点 $\mathbf{h}_i^0$ 在第 e 个子空间内的维度. T 代表向量的转置操作, “ $\cdot$ ”表示点积 (dot-product).

在子空间 e 中, 注意力机制计算各节点特征信息向量的过程可表示为:

$$\mathbf{h}'_{i,e} = \text{softmax}(u_{i,j}) \mathbf{v}_j = \sum_{j=1}^m \frac{\exp(u_{i,j})}{\sum_{j'} \exp(u_{i,j'})} \mathbf{v}_j, \quad i = 1, 2, \dots, m \quad (10)$$

其中 $\mathbf{v}_j = \mathbf{W}^V \mathbf{h}_j^0$ 表示节点 j 的 Value, $\mathbf{W}^V$ 为参数矩阵, 其维度为 $\dim \times \dim_e$, $\text{softmax}()$ 是归一化激活函数.

在子空间中计算完成的节点信息向量需粘接后进行整合, 节点 i 的整合计算式如下:

$$\text{MHA}(\mathbf{h}_i^0) = \mathbf{W}_Z^o [\mathbf{h}'_{i,1}; \mathbf{h}'_{i,2}; \dots; \mathbf{h}'_{i,Z}] \quad (11)$$

其中 $\mathbf{W}_Z^o$ 表示多头注意力机制的特征融合层的参数矩阵, 维度为 $\dim \times \dim$, “[$\cdot$]”为向量的粘接操作.

以上为第 1 层注意力机制的计算过程, 其余各层的计算过程与之相同, 不再赘述. 注意力层与层之间通过残差连接 (Skip-Connection)^[34] 和批标准化处理 (Batch-normalization)^[35] 进行连接, 计算式如下:

$$\hat{\mathbf{h}}_i^{l'} = \text{BN}(\hat{\mathbf{h}}_i^{l-1} + \text{MHA}^l(\hat{\mathbf{h}}_i^{l-1})), \quad i = 1, 2, \dots, m \quad (12)$$

$$\hat{\mathbf{h}}_i^l = \text{BN}^l(\hat{\mathbf{h}}_i^{l'} + \text{FF}(\hat{\mathbf{h}}_i^{l'})), \quad i = 1, 2, \dots, m \quad (13)$$

其中 $\hat{\mathbf{h}}_i^{l'}$ 为层与层之间的中间结果, FF 表示第 l 层的前馈神经网络, $\mathbf{h}_i^l$ 表示第 l 层的计算结果. 当特征

信息到达最后一层时, 可得到最终的编码信息 $\tilde{\mathbf{H}} = [\tilde{\mathbf{h}}_1, \tilde{\mathbf{h}}_2, \dots, \tilde{\mathbf{h}}_m]$, 同时可计算所有节点的聚合信息:

$$\bar{\mathbf{h}} = \frac{1}{m} \sum_{i=1}^m \tilde{\mathbf{h}}_i \quad (14)$$

4.3 车辆轮换机制

在本文 PDPC 场景中, 平台需要同时为多个众包车辆规划路径, 采用现有 Transformer 的串行的路径生成策略, 容易产生次优解. 因此本文引入一种并行的路径生成策略, 即在每个时间步轮换解码车辆. 为了找到一种自适应的轮换策略, 本文设计了一个车辆轮换神经网络, 对车辆的轮换策略进行学习. 车辆轮换神经网络的计算流程如图3所示.

首先, 构建车辆的状态信息提取层. 在 PDPC 中, 车辆的特征包括: 车辆原定行车距离, 即其起点到终点的距离 $l_{n_{o_v}^2, n_{d_v}^2}$; 车辆已行驶的距离 $L_{v,t-1}$; 车辆上一个访问节点的特征信息 $\tilde{\mathbf{h}}_{v,t-1}$; 车辆原定终点的特征信息 $\tilde{\mathbf{h}}_{d_v^2}$; 以及该车辆已在时间步 t 之前已被规划的路径图 $\mathbf{G}_{v,t-1} = [\tilde{\mathbf{h}}_{v,1}, \tilde{\mathbf{h}}_{v,2}, \dots, \tilde{\mathbf{h}}_{v,t-1}]$. 由于该路径图在系统中的表现形式为 $\dim \times (t-1)$ 维的矩阵, 不利于后续计算, 故本文通过最大池化操作对其进行聚合, 即 $\bar{\mathbf{G}}_{v,t-1} = \max(\mathbf{G}_{v,t-1})$, 将其转换为 $\dim$ 维向量.

另外, 为了将车辆的所有特征信息粘接为一个整体, 需要事先对车辆的特征信息 $(l(n_{o_v}^2, n_{d_v}^2), L_{v,t-1})$ 进行处理, 以统一维度, 其处理方式如下:

$$\mathbf{f}_{v,t} = \mathbf{W}^{F1} [l_{n_{o_v}^2, n_{d_v}^2}; L_{v,t-1}] + \mathbf{b}^{F1} \quad (15)$$

其中, 参数矩阵 $\mathbf{W}^{F1}$ 的维度为 $\dim \times 2$, 偏置项 $\mathbf{b}^{F1}$ 的维度为 $\dim$, 处理后 $\mathbf{f}_{v,t}$ 的维度为 $\dim$.

随后将已得到的特征信息粘接后输入前馈神经网络中, 得到每个车辆的深度特征, 其计算表达式如下:

$$\tilde{\mathbf{f}}_{v,t} = \text{FF}(\mathbf{W}^{F2} [\mathbf{f}_{v,t}; \tilde{\mathbf{h}}_{v,t-1}; \tilde{\mathbf{h}}_{d_v^2}; \bar{\mathbf{G}}_{v,t-1}] + \mathbf{b}^{F2}) \quad (16)$$

其中, $\tilde{\mathbf{f}}_{v,t}$ 的维度为 $\dim$, $\mathbf{W}^{F2}$ 的维度为 $\dim \times (4\dim)$, $\mathbf{b}^{F2}$ 的维度为 $\dim$, FF 表示带有 ReLU 激活函数的前馈神经网络.




图3 车辆轮换神经网络结构

然后将所有车辆的深度背景信息进行粘接并通过一个线性投影进行聚合, 计算方法如下:

$$\mathbf{F}_t = \mathbf{W}^{F3} [\tilde{\mathbf{f}}_{1,t}, \tilde{\mathbf{f}}_{2,t}, \dots, \tilde{\mathbf{f}}_{|V|,t}] + \mathbf{b}^{F3} \quad (17)$$

其中, $\mathbf{F}_t$ 的维度为 $\dim$, $\mathbf{W}^{F3}$ 的维度为 $|V| \times \dim$, $\mathbf{b}^{F3}$ 的维度为 $|V|$, $\mathbf{F}_t$ 的维度为 $|V|$.

最后将众包车辆特征矩阵输入 softmax() 函数中, 可得到各车辆被选择的概率向量 $\boldsymbol{\rho}_t^1$, 其表达式为:

$$\boldsymbol{\rho}_t^1 = \text{softmax}(\mathbf{F}_t) \quad (18)$$

其中, $\boldsymbol{\rho}_t^1$ 表示一个 $|V|$ 维的向量.

4.4 路径生成神经网络

路径生成神经网络处于 Encoder-Decoder 神经网络架构的 Decoder 端, 其原理是通过注意力模块计算当前众包车辆上一个访问节点的特征信息与其余节点的适配性 (Compatibility). 然后利用掩码机制遮掩不符合该车辆约束的节点, 阻止这些不可行节点被选出. 路径生成神经网络的计算流程如图4所示, 其具体计算步骤如下:




图4 路径生成神经网络结构

首先获取当前车辆 v 在 $t-1$ 时刻所在节点的编码信息 $\tilde{h}_{v,t-1}$ 和所有节点的聚合信息 $\bar{h}$, 并将上述信息粘接为一个整体:

$$\mathbf{H}_t = [\bar{h}; \tilde{h}_{v,t-1}] \quad (19)$$

随后将 $\mathbf{H}_t$ 和 $\tilde{\mathbf{H}}$ 输入至多头注意力机制中, 此处的多头注意力机制的结构与 4.2.2 节中描述的相同. 通过此处的计算可得到 glimpse: $\tilde{\mathbf{H}}_t$,

$$\tilde{\mathbf{H}}_t = \text{MHA}(\mathbf{H}_t \mathbf{W}^{Qd}, \tilde{\mathbf{H}} \mathbf{W}^{Kd}, \tilde{\mathbf{H}} \mathbf{W}^{Vd}) \quad (20)$$

其中, $\mathbf{W}^{Qd}$ 、 $\mathbf{W}^{Kd}$ 和 $\mathbf{W}^{Vd}$ 的维度为 $Z \times \frac{\dim}{Z} \times \dim$.

接着利用 $\tilde{\mathbf{H}}_t$ 和 $\tilde{\mathbf{H}}$ 计算各节点与当前车辆上一次访问节点的配合度,

$$\mathbf{u}_t = S \cdot \tanh \left(\frac{(\tilde{\mathbf{H}}_t \mathbf{W}_t^{Qs})^T \cdot (\tilde{\mathbf{H}} \mathbf{W}_t^{Ks})}{\sqrt{\dim_e}} \right) \quad (21)$$

其中, $\mathbf{W}_t^{Qs}$ 和 $\mathbf{W}_t^{Ks}$ 的维度为 $\dim \times \dim$, S 表示缩放系数, $\mathbf{u}_t$ 是一个 m 维向量, 可表示为 $\mathbf{u}_t = (u_{1,t}, \dots, u_{m,t})$.

然后使用掩码 $\text{mask}(\cdot)$ 对不可行节点进行遮盖.

$$\mathbf{u}'_t = \text{mask}(\mathbf{u}_t) \quad (22)$$

最后, 使用 $\text{softmax}(\cdot)$ 函数对配合度进行归一化处理, 得到各节点被选取的概率, 并通过采样的方式选择合适的节点.

$$\rho_t^2 = \text{softmax}(\mathbf{u}'_t) \quad (23)$$

其中 ρ_t^2 是一个 m 维的向量.

5 数值模拟实验

为了测试所提深度强化学习算法的表现, 本节对训练完成的模型开展多项测试 (模型的训练参数及过程见附录 C). 首先, 在小规模实例上与商用求解器 Gurobi 进行对比分析, 然后在中大规模实例上与传统启发式算法、智能算法进行对比分析, 随后进行了消融实验、以及泛化能力分析, 最后使用真实数据对模型进行测试.

5.1 小规模问题最优性对比分析

为了测试本算法求得的解与最优解之间的差距, 本文将所提算法与商用求解器 Gurobi 进行对比分析. Gurobi 是最先进的商用求解器之一, 在小规模问题上能够取得精确解. 本节使用两个随机生成的数据集对模型进行测试, 第一个数据集的问题规模为 3 个车辆 6 个任务, 共 18 个坐标节点, 包含 6 个车辆相关节点, 12 个任务相关节点, 该数据集一共有包含 20 个测试数据. 第二个数据集的问题规模为 4 个车辆 8 个任务, 包含 24 个坐标节点, 该数据集共有 15 个测试数据. 采样次数对模型的最终表现有重要影响 (实验结果见附录 D), 因此, 本节中模型的采样次数分为 1280 和 12800 两种, 采样次数为 1280 的算法记作 DRLM1, 采样次数为 12800 的记作 DRLM2. 对比结果见表 1, 实验结果为各类数据集中所有测试数据的平均值.

表 1 最优实验结果对比

方法	3V-6T			4V-8T		
	结果	差距 (%)	计算时间 (s)	结果	差距 (%)	计算时间 (s)
Gurobi	22.62	0	853.6	28.43	0	1200.65
DRLM1	23.83	5.35	0.09	30.05	5.70	0.13
DRLM2	23.55	4.11	0.15	29.70	4.47	0.24

从表 1 中可以看出, 对于问题规模 3V-6T, DRLM1 的最优差距为 5.35%, 高于 DRLM2 (4.11%). 这是因为 DRLM2 增加了采样次数, 能够同时生成更多的备选解, 从而找到更优解的概率更大. 对于问题规模 4V-8T, 也得到了类似的结果. 从计算时间来看, 本文所提算法的计算时间相较于 Gurobi 更短. 总体来说, 本文所提的方法求得的解与最优解接近, 并且计算时间远低于精确算法.

5.2 中大规模问题算法性能对比分析

本节测试所提算法在中大规模问题上的表现. 本文设置了 4 个众包车辆和 10 个众包车辆两个情景, 并分别针对这两个情景分别设置了 4 个问题规模, 分别 4V-12T、4V-16T、10V-30T、以及 10V-40T. 以 4V-12T 为例, 该问题规模表示有 4 个众包车辆, 12 个运输任务, 共包含 8 个众包车辆的“起-终”节点和 24 个运输任务的“取-送”节点在内的 32 个节点. 本节按照 5.1 节中的数据生成规则分别为每个实验随机生成了 10 组数据, 结果取 10 组数据的平均值.

对比算法方面, 选取的启发式算法有: 自适应大邻域搜索算法 (Adaptive large neighborhood search, ALNS)、忌搜索算法 (Tabu Search, TS)、和遗传算法 (Genetic Algorithm, GA), 基于学习的算法有: 注意力机制 (Attention mechanism, AM)^[4], POMO (Policy Optimization with Multiple Optima) 算法^[36]. 关于以上对比算法, 本文在开源代码的基础上将上述算法迁移至本文所研究问题, 超参数保持不变. 结果见图 5, 其中纵轴表示各优化算法所得路径策略的总行驶距离. 计算时间的对比结果见表 2.

从图 5 可以看出, 基于学习的算法所得结果的总行驶路径长度明显低于元启发式算法, 因此可以说学习类算法相比于元启发式算法在性能上具有一定的优越性, 此外, 本文所提算法所得总行驶距离也低于 AM 和 POMO 算法, 该实验结果也表明了, 本文对于 Transformer 神经网络的改进是有效的. 在计算时间方面, 从表 2 中可以看出, 基于学习的算法的求解时间远低于元启发式算法. 这一现象可以归因于学习型算法能够通过大量的训练样本学习到问题的求解规律, 因此在面对类似问题时, 能够根据问题的特征快速给出解决方案. 相对而言, 启发式算法在每次求解新问题时, 都必须经历完整的迭代过程,

这无疑会消耗更多的时间. 为了深入分析算法之间路径规划方案的区别, 本文对路径进行了可视化分析, 详见附录 E.




图 5 对比结果

表 2 各算法的计算时间对比结果

算法	计算时间 (s)			
	4V-12T	4V-16T	10V-30T	10V-40T
ALNS	109.23	177.69	358.70	919.15
GA	98.31	166.28	342.63	903.66
TS	106.21	170.91	355.31	910.65
AM	0.12	0.16	0.33	0.52
POMO	0.11	0.15	0.33	0.53
DRLM1	0.16	0.27	0.70	0.98
DRLM2	0.46	0.64	1.84	3.61

5.3 消融实验

为了进一步测试车辆轮换策略在算法性能方面起到的作用, 本节对其进行消融实验. 首先, 以 AM 作为基准算法, 用以模拟采用“串行生成”策略的算法, 其次, 设置 rDRLM 和 sDRLM^[37] 两算法采用“并行生成”的策略, 其中, rDRLM 表示在每个时间步随机轮换众包车辆, sDRLM 表示按照顺序依次轮换众包车辆, 而本文提出的 DRLM2 则使用车辆轮换神经网络挑选每次轮换的车辆. 此外, 为了测试嵌入神经网络和路径生成神经网络中注意力机制对整体性能的影响, 本文分别在完全去除注意力机制和单头注意力机制两种条件下对模型进行训练并测试. 在完全去除注意力机制的实验中, 我们把注意力机制替换成指针神经网络^[23], 记作 Po.NT. 另外, 把单头注意力机制条件下的模型记作 1He.AT. 消融实验在问题实例 10V-30T 和 10V-40T 上进行, 实验结果见表 3.

从表 3 看出, 相比于采用“串行生成”策略的 AM, 采用“并行生成”策略的 DRLM2 在性能表现上有较大提升. 而对于“并行生成”, 相比于随机轮换和按顺序轮换, 使用车辆轮换神经网络进行轮换的策略取得了最好的性能提升效果. 因此本文提出的改进策略是有效的. sDRLM 算法采用顺序原则切换当前车辆, 导致每个车辆接到的任务数量完全一致. 然而, 在实际情景中, 有些众包车辆的原定行程较远, 可携带更多的运输任务, 有些车辆原定行程较近, 无法携带过多任务, 因此 sDRLM 的轮换策略会在一定程度上增加绕行. 而 rDRLM 在每个时间步中随机切换规划车辆会增大噪声, 干扰神经网络的学习效率. 此外, 当完全去除注意力机制后, 模型的性能大幅下降, 最终表现低于基准模型. 当把多头注意力机制替换为单头注意力机制时, 模型的性能轻微下降. 由以上实验结果可以看出, 本文对算法的改进是有

表 3 消融实验结果

算法	10V-30T		10V-40T	
	行驶距离	效果提升	行驶距离	效果提升
AM	113.67	0.00%	133.93	0.00%
tDRLM	110.42	2.86%	129.91	3.00%
sDRLM	109.81	3.40%	128.58	3.99%
Po.NT	121.31	-6.72%	143.38	-7.05%
1He.AT	110.57	2.73%	130.29	2.72%
DRLM2	106.64	6.18%	127.82	4.56%

效的.

5.4 泛化能力分析

泛化能力是基于学习的算法的重要性能之一,是指训练完成的算法在未学习过的问题或数据上的表现.充分利用算法的泛化能力,能够有效降低算法的训练成本.本节首先测试模型在不同问题规模上的泛化能力.测试结果见表4.表4中第一列表示在不同问题规模进行一轮完整训练得到的模型.如“Trai.On 10V-30T”表示使用问题规模为10V-30T的训练数据训练完成的模型.从表中的结果可以看出,当对模型进行非跨规模测试时,模型的效果损失为0.00%,而进行跨规模测试时,模型的性能在一定程度上有所下降.如模型“Trai.On 10V-30T”在问题规模为10V-30T上的效果损失为0.00%,而当在10V-40T上进行测试时,性能损失了3.22%.总体来看,尽管在进行跨规模测试时,模型的性能会有所下降,但在一个合理的范围.由此可以说明,经过训练的模型在问题规模方面具备一定的迁移能力.

表 4 任务规模泛化能力测试

模型	10V-30T		10V-40T	
	行驶距离	性能损失	行驶距离	性能损失
Trai.On 10V-30T	106.64	0.00%	131.93	-3.22%
Trai.On 10V-40T	109.42	-2.61%	127.82	0.00%
Trai.On 4V-12T	110.81	-3.76%	133.23	-4.03%
Trai.On 4V-16T	111.06	-4.14%	134.15	-4.95%

此外,为了测试模型在节点分布方面的泛化能力,本文分别用高斯分布和真实路网分布下的训练数据对模型进行训练.训练数据的节点分布示意图见附录F.使用高斯分布训练的模型记为“Trai.On Gau.DisT.”,使用成都路网分布训练的模型记为“Trai.On CheD.DisT.”.本文的基础模型为“Trai.On Uni.DisT.”,该模型使用均匀分布进行训练.

与问题规模泛化能力类似,本节对模型进行非跨分布和跨分布测试,测试结果见表5.从表5中的结果可以看出,当模型进行跨分布测试时,模型的性能出现的一定程度的下降,但性能的下降幅度依然较低,因此可以说明所提模型在不同节点分布之间也具有一定的泛化能力.

表 5 节点分布泛化能力测试

模型	Gau.DisT.		CheD.DisT.	
	行驶距离	效果损失	行驶距离	效果损失
Trai.On Gau.DisT.	91.71	0.00%	88.65	-6.67%
Trai.On CheD.DisT.	95.46	-4.10%	83.11	0.00%
Trai.On Uni.DisT.	94.68	-3.24%	86.23	-3.75%

5.5 真实数据案例分析

本节采用一个真实场景来测试所提出方法的应用效果. 真实数据由美团提供 (<https://github.com/meituan/Meituan-INFORMS-TSL-Research-Challenge>), 包括 2022 年 10 月 17 日至 10 月 24 日某个城市的订单数据. 本文选择了前五天的数据进行测试. 第一至五天的数据分别包含了 330、361、369、355 和 392 个订单, 其中第一天的订单分布见附录 G. 为了使已经训练好的神经网络能够更好的拟合该数据, 我们对该数据进行了归一化处理. 由于数据中未包含众包车辆的起点和终点的坐标信息, 本文在该地图场景分别按均匀分布和集中分布两种方式, 随机生成了 50 个众包车辆的起点和终点坐标. 均匀分布是指众包车辆的起点和终点均匀分布在地图之中, 集中分布是指众包车辆的起点和终点较为集中地分布在地图中心区域.

表 6 真实数据测试结果

问题实例	方法	均匀分布		集中分布	
		结果	计算时间 (s)	结果	计算时间 (s)
1	AM	185.51	20.32	206.32	20.32
	DRLM2	178.63	25.65	197.21	25.05
2	AM	196.13	23.10	219.33	23.16
	DRLM2	181.85	27.85	199.85	27.85
3	AM	215.29	22.25	236.74	22.27
	DRLM2	191.36	27.93	219.36	27.93
4	AM	245.86	21.57	269.26	21.98
	DRLM2	233.16	28.37	259.31	28.47
5	AM	218.47	21.85	237.78	21.66
	DRLM2	195.27	28.57	218.35	28.57

由于该数据集的节点规模较大, 传统启发式算法的计算时间非常长, 因此本文仅采用 AM 算法作为基准. 本节测试结果见表 6. 从表 6 的结果可以看出, 同为机器学习算法, AM 算法和本文所提出的 DRLM2 算法都能在合理时间内给出可行结果, 并且本文所提算法所得结果更优. 因此可以说明, 本文所题算法具有较好的拓展能力, 能够适用于真实应用场景的路径规划需求. 此外, 对比众包车辆均匀分布和集中分布条件下的测试结果, 集中分布下的行驶距离明显高于均匀分布, 这是由于均匀分布下, 有更大的机会将运输任务分配给顺路的众包车辆, 从而减少了总的行驶距离.

6 结论

本文围绕众包模式下的路径规划问题展开研究, 聚焦于“车辆与任务均具有独立起终点”这一典型特征, 构建了众包平台视角下的马尔可夫决策模型. 针对现有基于“串行生成”策略的深度学习方法在多车辆任务规划中的局限性, 本文提出一种融合车辆轮换网络的“并行生成”机制, 并结合 Transformer 结构设计了高效的深度强化学习算法, 用于同时为多个众包车辆进行路径规划. 通过引入结构改进与机制创新, 提升了算法在复杂众包场景中的适应性与扩展性. 基于不同规模问题的数值实验, 本文得到如下主要结论: (1) 在小规模实例中, 所提算法可获得接近最优的路径规划结果; 在中大规模问题中, 其求解质量与速度均优于精确算法、启发式算法与现有智能算法. (2) “并行生成”策略显著增强了算法的可扩展性和多车辆调度能力; (3) 所提算法具备良好的泛化能力与极短的计算时间, 展示出较强的实际部署潜力.

本文在建模过程中假设所有运输任务均为小件包裹, 未考虑众包车辆的运力限制与任务的服务时间窗. 这一设定主要基于当前主流众包配送平台以轻小件订单为主的运营特征, 以及模型设计对计算复

杂度的控制需求. 然而在实际应用中, 运力与时间窗约束常常是影响路径可行性与调度效率的关键因素. 因此, 未来研究可在现有模型基础上, 引入运力限制与时间窗约束等更具现实性的参数设定, 进一步提升算法在复杂场景下的适用性与推广能力. 同时, 也可探索任务优先级、软性时间窗等多维约束下的调度策略, 拓展模型在多类型配送需求中的应用边界.

参考文献

- [1] Savelsbergh M W P, Ulmer M W. Challenges and opportunities in crowdsourced delivery planning and operations[J]. 4OR, 2022, 20 (1): 1-21.
- [2] Arslan A M, Agatz N, Kroon L, et al. Crowdsourced delivery—a dynamic pickup and delivery problem with ad hoc drivers[J]. Transportation Science, 2019, 53(1): 222-235.
- [3] Behrend M, Meisel F, Fagerholt K, et al. An exact solution method for the capacitated item-sharing and crowdshipping problem[J]. European Journal of Operational Research, 2019, 279(2): 589-604.
- [4] Han C K, Cheng S F. An exact single-agent task selection algorithm for the crowdsourced logistics[C]. IJCAI, 2020.
- [5] Torres F, Gendreau M, Rei W. Crowdshipping: An open VRP variant with stochastic destinations[J]. Transportation Research Part C: Emerging Technologies, 2022, 140: 103677.
- [6] Mousavi K, Bodur M, Roorda M J. Stochastic last-mile delivery with crowd-shipping and mobile depots[J]. Transportation Science, 2022, 56(3): 612-630.
- [7] Torres F, Gendreau M, Rei W. Vehicle routing with stochastic supply of crowd vehicles and time windows[J]. Transportation Science, 2022, 56(3): 631-653.
- [8] Nieto-Isaza S, Fontaine P, Minner S. The value of stochastic crowd resources and strategic location of mini-depots for last-mile delivery: A benders decomposition approach[J]. Transportation Research Part B: Methodological, 2022, 157: 62-79.
- [9] Boysen N, Emde S, Schwerdfeger S. Crowdshipping by employees of distribution centers: Optimization approaches for matching supply and demand[J]. European Journal of Operational Research, 2022, 296(2): 539-556.
- [10] Pugliese L D P, Ferone D, Macrina G, et al. The crowd-shipping with penalty cost function and uncertain travel times[J]. Omega, 2023, 115: 102776.
- [11] Su E, Qin H, Li J, et al. An exact algorithm for the pickup and delivery problem with crowdsourced bids and transshipment[J]. Transportation Research Part B: Methodological, 2023, 177: 102831.
- [12] Stokkink P, Cordeau J F, Geroliminis N. A column and row generation approach to the crowd-shipping problem with transfers[J]. Omega, 2024, 128: 103134.
- [13] Kaffle N, Zou B, Lin J. Design and modeling of a crowdsourcing-enabled system for urban parcel relay and delivery[J]. Transportation Research Part B: Methodological, 2017, 99: 62-82.
- [14] 周林, 陈燕萍, 李海燕, 等. 基于众包捎带协作的协同配送优化研究 [J]. 运筹与管理, 2023, 32 (07): 78-84.
Wu L, Cheng Y, Li H, et al. Research on collaborative delivery optimization based on crowdsourcing and piggyback collaboration[J]. Operation Research and Management Science, 2023, 32 (07): 78-84.
- [15] Macrina G, Pugliese L D P, Guerriero F, et al. Crowd-shipping with time windows and transshipment nodes[J]. Computers & Operations Research, 2020, 113: 104806.
- [16] 葛显龙, 刘小宁, 姜云云. 众包模式下考虑不同交付方式的配送路径优化研究 [J]. 计算机工程与应用, 2025, 61 (09): 370-380.
Xian L, Liu X, Jiang Y. Research on distribution route optimization considering different delivery methods in crowdsourcing mode[J]. Computer Engineering and Applications, 2025, 61 (09): 370-380.
- [17] Elsokkary N, Otrók H, Singh S, et al. Crowdsourced last mile delivery: Collaborative workforce assignment[J]. Internet of Things, 2023, 22: 100692.
- [18] Hamid M, Nasiri M M, Rabbani M. A mixed closed-open multi-depot routing and scheduling problem for home-made meal delivery incorporating drone and crowd-sourced fleet: A self-adaptive hyper-heuristic approach[J]. Engineering Applications of Artificial Intelligence, 2023, 120: 105876.
- [19] Longo G L. A metaheuristic approach to crowdsourced package delivery[D]. Technische Universität Wien, 2023.
- [20] Zheng J, Wang L, Wang L, et al. Solving stochastic online food delivery problem via iterated greedy algorithm

- with decomposition-based strategy[J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2022, 53(2): 957-969.
- [21] Liang X, Yang H, Wang Z. Rolling optimal scheduling for urban parcel crowdsourced delivery with new order insertion[J]. *Computers & Operations Research*, 2024, 171: 106779.
- [22] 周煜丰, 吴志彬, 向传凯, 等. 考虑需求可拆分的雇佣和众包车辆协同运输路径规划模型 [J/OL]. *中国管理科学*, 2024, 1-16.
Zhou Y., Wu Z., Xiang C., et al. A collaborative route planning model for hiring and crowdsourcing vehicles with split delivery [J]. *Chinese Journal of Management Science*, 2024, 1-16.
- [23] Vinyals O, Fortunato M, Jaitly N. Pointer networks[J]. *Advances in Neural Information Processing Systems*, 2015, 28: 1-15.
- [24] Bello I, Pham H, Le Q V, Norouzi M, Bengio S. Neural combinatorial optimization with reinforcement learning[C]. *Proceedings on 5th International Conference Learning Representations*, 2017: 1-15.
- [25] Nazari M, Oroojlooy A, Snyder L, Takac M. Reinforcement learning for solving the vehicle routing problem[J]. *Advances in Neural Information Processing Systems*, 2018, 31, 1-11.
- [26] Kool W, Van Hoof H, Welling M. Attention, learn to solve routing problems![C]. *Proceedings on 7th International Conference Learning Representations*, 2019: 1-25.
- [27] James J Q, Yu W, Gu J. Online vehicle routing with neural combinatorial optimization and deep reinforcement learning[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2019, 20 (10): 3806-3817.
- [28] Li J, Xin L, Cao Z, et al. Heterogeneous attentions for solving pickup and delivery problem via deep reinforcement learning[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021, 23 (3): 2306-2315
- [29] Guo F, Wei Q, Wang M, et al. Deep attention models with dimension-reduction and gate mechanisms for solving practical time-dependent vehicle routing problems[J]. *Transportation Research Part E: Logistics and Transportation Review*, 2023, 173: 103095.
- [30] Fan M, Wu Y, Liao T, et al. Deep reinforcement learning for UAV routing in the presence of multiple charging stations[J]. *IEEE Transactions on Vehicular Technology*, 2022, 72(5): 5732-5746.
- [31] Zhang K, Li M, Wang J, et al. A Two-stage Learning-based method for Large-scale On-demand pickup and delivery services with soft time windows[J]. *Transportation Research Part C: Emerging Technologies*, 2023, 151: 104122.
- [32] Ye H, Wang J, Liang H, et al. Glop: Learning global partition and local construction for solving large-scale routing problems in real-time[C]. *Proceedings of the AAAI Conference on Artificial Intelligence*. 2024, 38(18): 20284-20292.
- [33] 向传凯, 吴志彬, 徐玖平. 双智能体协作学习的众包物流任务分配模型 [J]. *系统工程理论与实践*, 2023, 43 (07): 1978-1995.
Xiang C, Wu Z, Xu J. Collaborative learning with dual-intelligences for crowd logistics task assignment[J]. *Systems Engineering —Theory & Practice*. 2023, 43 (07): 1978-1995.
- [34] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C] *Proceedings on the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, 770-778.
- [35] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]. *International Conference on Machine Learning*, 2015, 448-456.
- [36] Kwon Y D, Choo J, Kim B, et al. Pomo: Policy optimization with multiple optima for reinforcement learning[J]. *Advances in Neural Information Processing Systems*, 2020, 33: 21188-21198.
- [37] Zhang K, He F, Zhang Z, Lin X, Li M. Multi-vehicle routing problems with soft time windows: A multi-agent reinforcement learning approach[J]. *Transportation Research Part C: Emerging Technologies*, 2020, 121: 102861.
- [38] Zou Y, Wu H, Yin Y, et al. An improved transformer model with multi-head attention and attention to attention for low-carbon multi-depot vehicle routing problem[J]. *Annals of Operations Research*, 2024, 339(1): 517-536.

附录

A PDPC 整数规划模型

PDPC 问题的整数规划模型如下:

$$\min \sum_{v \in V} \sum_{i \in N} \sum_{j \in N} l(i, j) x_{i,j}^v \quad (20)$$

s.t.

$$\sum_{v \in V} \sum_{j \in N^1 \cup \{d_v^2\}} x_{i,j}^v = 1, \quad \forall i \in N^1 \quad (21)$$

$$\sum_{v \in V} \sum_{j \in N^1 \cup \{d_v^2\}} x_{i,j}^v = 1, \quad \forall i \in O^2 \quad (22)$$

$$\sum_{i \in D^1 \cup \{o_v^2\}} x_{i,d_v^2}^v = 1, \quad \forall v \in V \quad (23)$$

$$\sum_{j \in O^1 \cup \{d_v^2\}} x_{o_v^2,j}^v = 1, \quad \forall v \in V \quad (24)$$

$$\sum_{i \in N^1} x_{i,j}^v - \sum_{i \in N^1} x_{j,i}^v = 0, \quad \forall j \in N^1, v \in V \quad (25)$$

$$\sum_{j \in N^1} x_{o_p^1,j}^v - \sum_{i \in N^1} x_{i,d_p^1}^v = 0, \quad \forall p \in P, \forall v \in V \quad (26)$$

$$B_{d_p^1} \geq t_{o_p^1,d_p^1} + B_{o_p^1}, \quad \forall p \in P \quad (27)$$

$$B_j \geq B_i + t_{i,j} - M(1 - x_{i,j}^v), \quad \forall i, j \in N^1, \forall v \in V \quad (28)$$

$$x_{i,j}^v \in \{0, 1\}, \forall i \in N^1 \cup \{o_v^2\}, j \in N^1 \cup \{d_v^2\}, \forall v \in V \quad (29)$$

$$B_i \geq 0, \forall i \in N \quad (30)$$

目标 (1) 表示最小化所有众包车辆的行驶距离; 约束 (2) 表示每个任务取货点或送货点仅能被访问一次; 约束 (3) 表示每个起点都只能出发一位车辆; 约束 (4) 和 (5) 表示车辆直接 (或完成某些任务后) 前往其对应的终点; 式 (6) 表示流量守恒约束; 约束 (7) 表示同一个任务的取货节点和送货节点必须由同一众包车辆访问; 约束 (8) 表示同一任务内的取送顺序约束, 要求车辆先到达取货节点 o_p^1 , 再到达送货节点 d_p^1 , 其中 $B_{o_p^1}$ 和 $B_{d_p^1}$ 为取货节点和送货节点的到达时间, $t_{o_p^1,d_p^1}$ 为行驶时间; 约束 (9) 表示节点间的时间衔接约束, 若车辆 v 从节点 i 前往节点 j ($x_{i,j}^v = 1$), 则到达 j 的时间不早于离开 i 的时间加上行驶时间, M 是足够大的正数, 用于放松未经过路径的约束. 约束 (10) 定义决策变量 $x_{i,j}^v$, 表示车辆 v 是否从节点 i 前往节点 j , 为 0-1 变量. 约束 (11) 确保每个节点的到达时间 B_i 为非负数.

B 训练算法

本文将上述神经网络结构纳入一个整体之中进行中心化训练. 训练算法为带有滚动基准的 **REINFORCE** 算法 [1], 该算法在神经网络架构不变的基础上预留两套神经网络参数, 分别为基准神经网络和策略神经网络. 令 θ 指代策略神经网络的所有参数, ϑ 指代基准神经网络的所有参数. 该算法在每个训练周期中, 基于损失函数利用反向传播的方式更新网络参数. 当解的质量显著优于上一训练周期时 (t-检验, 显著水平 $\alpha = 0.05$), 将策略网络的值赋值给基准神经网络.

首先基于奖励函数计算损失函数的梯度, 计算方式见式 (36), 其中 $R^\theta(\pi[1, |V|])$ 是策略网络获得的解的奖励值, $R^\vartheta(\pi[1, |V|])$ 是基准网络生成的解的奖励值, $\rho_\theta(\pi[1, |V|]|s)$ 表示在状态 s 下, 策略网络生

成路径策略 $\pi[1, |V|]$ 的概率. $\rho_{\theta}(\pi[1, |V|] | s)$ 的计算式为式 (37). 本文使用 **Adam** 优化器 [2] 通过神经网络的反向传播算法 [3] 对神经网络中的各参数进行更新优化, 以最小化损失函数.

$$\nabla L(\theta | s) = -\mathbb{E}_{\pi \sim \rho_{\theta}} [R^{\theta}(\pi[1, |V|]) - R^{\vartheta}(\pi[1, |V|])] \nabla \log \rho_{\theta}(\pi[1, |V|] | s) \quad (36)$$

$$\rho_{\theta}(\pi[1, |V|] | s) = \prod_{t=0}^{\pi[|V|-1]} (\rho_{\theta}(n_{t+1} | s_t, v_{t+1}) + \rho_{\theta}(v_{t+1} | s_t)) \quad (37)$$

训练算法伪代码见算法 1,

Algorithm 1: 深度强化学习训练算法

Input: 随机生成的众包物流任务/车辆实例数据集
Output: 策略 π

- 1 初始化: 策略网络和基准网络的参数 θ, ϑ ;
- 2 **for** 每个训练周期 **do**
- 3 **for** 每个训练批 **do**
- 4 令时间步 $t = 0$;
- 5 初始化状态 s_t ;
- 6 提取众包物流任务/车辆实例初始信息 $\bar{h}, \tilde{h}$ (4.2 节);
- 7 **while** 未访问节点集合非空 **do**
- 8 选择车辆 v (4.3 节);
- 9 生成下一访问节点 n_i (4.4 节);
- 10 更新状态 (4.1 节式 (12)-(16));
- 11 **end**
- 12 计算策略网络的总回报 R^{θ} (4.1 节式 (17));
- 13 计算基准网络的总回报 R^{ϑ} (4.1 节式 (17));
- 14 计算梯度 $\nabla L(\theta | s)$ (4.5 节式 (36));
- 15 使用 Adam 优化器更新策略网络参数 θ ;
- 16 **end**
- 17 **if** 单侧配对 T 检验 $T\text{-Test}(\pi_{\theta}, \pi_{\vartheta}) < 0.5$ **then**
- 18 更新基准网络参数 $\vartheta \leftarrow \theta$;
- 19 **end**
- 20 **end**

C 参数设置与模型训练

模型中的超参数均按照被已有文献广泛接受的数值进行设置 [2]. 网络嵌入维度设置为 $\dim = 128$, 前馈神经网络的隐层维度为 512 维, 编码器的注意力层数为 $C = 3$, 注意力头数为 $Z = 8$, Softmax 温度设置为 $SK = 2.5$, 策略和基准网络学习率分别为 $\eta_{\text{pol}} = 10^{-4}$ 和 $\eta_{\text{bas}} = 10^{-4}$, 学习衰减率为 0.995; 每个训练批次的实例个数为 512. 算法基于 Pytorch 编程实现, 并在一台配备了 AMD EPYC 7313P 16 核处理器、256GB 内存和 24GB 显存的 NVIDIA A30 GPU 的服务器上进行训练, 训练周期为 (epoch) 100, 每个训练周期有 250 个训练批次 (batch), 每个训练批次包含 512 个训练实例.

本文根据文献 [4] 中的实例生成规则生成训练数据和测试数据. 训练集和测试集中的位置节点均在 6×6 大小的地图中随机生成, 节点分布为均匀分布, 节点包括取货节点、送货节点、车辆起点、以及车辆终点. 训练过程中使用贪婪搜索策略, 测试过程中, 采用采样搜索策略. 采样搜索策略是使用策略网络生成多个可行解, 然后从中选优.

训练的收敛曲线见图6, 图中阴影曲线为实际曲线, 实体曲线为平滑后的曲线. 图6(a) 中展示模型在 10 个车辆 30 个任务的问题规模上收敛曲线, 纵坐标为运输距离. 图中实线为每个训练轮次结束时的验证值, 虚线为训练值. 从图6(a) 中的结果可以看出, 随着训练轮次的增加, 行驶距离逐渐减小并收敛. 图6(b) 绘制的是模型训练过程中的损失值. 从图6(b) 中可以看出, 模型的损失值逐渐收敛至 0. 因此, 以上结果可以说明, 本文所提模型具有较好的收敛性.




图 6 训练收敛曲线

D 采样次数敏感性分析

在前述章节中, 本文采用了不同采样次数的采样搜索策略对问题进行求解, 为了测试不同采样次数在不同问题规模上的表现差异, 本节对采样次数进行敏感性分析. 本分别在 4V-8T 和 10V-40T 两个问题规模上随机生成 20 个问题实例, 然后使用采样 128 次、1280 次、12800 次的算法求解这些问题实例, 并将测试结果以箱型图进行展示. 测试结果如图7所示, 图7a 和 b 分别表示算法在 4V-8T 和 10V-40T 下的行驶距离, 图中的横线表示中位数, 原点表示平均值. 图7c 为计算时间折线图.

从图7(a) 和 (b) 的结果可以看出, 当采样次数增加时, 所得结果的运输距离降低, 箱体变短, 这表明算法的性能得到有效的提升. 此外为了验证不同采样次数下算法的表现是否具有显著差异, 本文使用 t-test 对 20 组实验的测试结果进行统计学分析, 分析表明, 不同采样次数下的求解质量存在显著差异 ($p < 0.001$). 从图7(c) 的结果可以看出, 在求解小规模问题 (4V8T) 时, 计算时间对采样次数的增加不敏感, 但在求解中大规模问题时 (10V40T), 计算时间随采样次数增长明显. 以上实验结果表明, 尽管增加采样次数能够在一定程度上提升解的质量, 但也会增加计算开销.

E 可视化分析

为了直观地对比各算法的路径规划方案, 本节绘制了各算法在问题规模为 3V9T 的路径规划策略. 由于篇幅有限, 本文仅展示 ALNS、sDRLM、以及 DRLM2 的结果, 路径规划结果见图 8. 总体来看, 在 3 种算法中, ALNS 生成的路径策略的总距离较长, sDRLM 和 DRLM2 生成的路径策略的总距离相对较短. 相较于 sDRLM 和 DRLM2 的路径, ALNS 生成的路径相对杂乱, 在路径中存在着一些不合理的绕行, 如在图 8(a) 中, 众包车辆 3 完成任务 3 后本可直接回到其终点, 但 ALNS 在众包车辆 3 的路径中插入了任务 8, 导致车辆 3 需要继续访问任务 8 的取货点, 并绕行至送货点送货后再返回终点.

从图 8(b) 和图 8(c) 可以看出, sDRLM 和本文所提的 DRLM2 生成的路径较为类似. sDRLM 和 DRLM2 为车辆 3 生成了相同的路径, 路径为 $o_3-7-5-7-3-d_3$. sDRLM 为众包车辆 1 和 2 生成的路径分别为: $o_1-6-9-6-8-9-d_1$ 和 $o_2-1-4-2-4-1-2-d_2$, 而 DRLM2 生成的路径为: $o_1-6-9-6-2-8-9-d_1$ 和 $o_2-1-4-4-1-d_2$. 由此可见, sDRLM 和 DRLM2 两种算法生成的策略的关键区别在于任务 2 的分配问题上. sDRLM 将任务 2 分配给了车辆 2, 而 DRLM2 将任务 2 分配给了车辆 1, 该差异使得 DRLM2 的路径总距离更短.




图 7 采样次数敏感性分析




图 8 路径可视化

造成该差异的原因是: sDRLM 采用顺序轮换的方式确定众包车辆, 这导致众包车辆被分配的任务数量完全相同, 这一结论能从分配结果得到印证。从 sDRLM 的路径分配结果可以看出, 每辆众包车辆均被分配了 3 个任务。而本文通过神经网络轮换众包车辆, 充分考虑了众包车辆的原定行程, 在路径规划过

程中能够自适应地调整任务分配数量, 并规划合适的行驶路径, 降低路径的总体成本.

F 训练数据节点分布示意图


训练数据的节点分布示意图见图9. 图9(a) 为高斯分布, 图9(b) 为从成都武侯区路网中提取的节点分布.

G 任务分布示意图


订单分布如图 10 所示.

参考文献

- [1] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. MIT Press, 2018.
- [2] Kingma DP, Ba JL. Adam: A method for stochastic gradient descent[C]. Proceedings on 3rd International Conference Learning Representations, 2015, 1-15.
- [3] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323(6088): 533-536.
- [4] Kool W, Van Hoof H, Welling M. Attention, learn to solve routing problems![C]. Proceedings on 7th International Conference Learning Representations, 2019: 1-25.



(a) 高斯节点分布



(b) 成都武侯区节点分布

图 9 测试节点分布情况




图 10 任务坐标分布