

面向连续泊位和岸桥动态调度问题的强化学习方法

王 苓, 王 钰, 梁承姬

(上海海事大学 物流科学与工程研究院, 上海 201306)

摘 要:近年来集装箱吞吐量增加、作业设备智能化程度提升,使得港口对动态环境下泊位与岸桥联合调度的要求不断提高。为充分利用动态环境中的大量数据从而作出高效的优化决策,本文将连续泊位—岸桥调度问题考虑为序列决策问题,构建了相应的马尔可夫决策过程,提出了一种基于近端策略优化(Proximal Policy Optimization, PPO)的深度强化学习算法。该算法充分考虑了岸桥的动态移动、船舶动态抵港情况,设计了合理的状态空间、动作空间和奖励函数,算法通过与大规模复杂场景下的动态环境不断交互获得连续泊位—岸桥联合优化的最佳调度方案。多个算例的测试结果表明本文所提出的 PPO 算法能够充分适应不同问题规模和动态环境,相较于传统的调度决策方法更具优势:与遗传算法和粒子群算相比,其计算效率提升了 93.21% 和 93.01%,决策目标平均改进了 15.7% 和 20.3%;与 DDPG 强化学习算法相比在收敛速度上更快,通过对比在几组不同算例下的决策目标改进了 6.5%~10% 的作业时间。

关键词:泊位岸桥调度;深度强化学习;连续泊位分配;岸桥动态调度;PPO 算法

中图分类号:TP181 **文章标识码:**A **文章编号:**1007-3221(2025)08-0185-07 **doi:**10.12005/orms.2025.0260

A Reinforcement Learning Approach for Joint Optimization of Continuous Berth Allocation and Quay Crane Scheduling

WANG Ling, WANG Yu, LIANG Chengji

(Institute of Logistics Science and Engineering, Shanghai Maritime University, Shanghai 201306, China)

Abstract: Container ports are important maritime hubs that connect trade between countries. In daily operations, ports need to allocate limited berth and quay crane resources to ships within a planning period based on multiple factors such as arrival time, ship type, workload, and departure plans, to ensure that all ships complete their operations as soon as possible. The decisions of berth allocation and quay crane scheduling usually rely on an intuition and experience of port staff, which can easily lead to a prolonged vessel stay in port or a waste of limited resources. Moreover, in the trend of large-sized ships, increasing port throughput, and the gradual popularization of intelligent equipment and systems, a large amount of operational data has been accumulated during daily operations. More scientific and intelligent decision-making methods are urgently required for berth and crane scheduling to further improve port operation efficiency and resources utilization, especially in complex large-scale dynamic environments.

The problem of port resources allocation and equipment scheduling has attracted the attention of many scholars, but existing research on berth allocation usually considers the coastline to be discrete into multiple berths, which cannot truly depict the actual situation of the coastline. And existing research on crane scheduling mostly considers static task sets and fails to meet the real-time scheduling needs of ports in complex environments. At present, many scholars have proposed various solutions to berth allocation and crane scheduling problems. But most of them consider the two related decisions separately, and ones using machine learning techniques only optimize the parameters in the traditional algorithms without taking full advantage of the adaptive and efficient characteristics of reinforcement learning.

In order to meet the needs of intelligent decision-making of port berth and crane scheduling in a large-scale complex dynamic environment, this paper considers a joint optimization problem of continuous berth allocation

收稿日期:2023-02-08

基金项目:上海市青年科技英才扬帆计划(21YF1416400);上海市“科技创新行动计划”软科学研究项目(22692111200)

作者简介:王苓(1994-),女,山东费县人,硕士,研究方向:港口调度优化;王钰(1989-),通讯作者,女,河北秦皇岛人,博士,讲师,研究方向:汽车物流,物流优化算法。Email: wangyu@shmtu.edu.cn。

and quay crane dynamic scheduling. The problem is considered to be a sequencing one and is described as a Markov Decision Process (MDP) with carefully designed state space, action space, and reward functions. An efficient reinforcement learning method is proposed by combining A2C (Actor to Critical) neural network with Proximal Policy Optimization (PPO).

The PPO-based method is trained and tested based on real data from a port in Shanghai, China. Each episode of the training process contains 72 steps of interactions with the environment, and the agent updates the model every 100 steps. During the training process, the stage training results are saved every 1000 episodes. The training process stabilizes and converges after 60 thousand episodes. Based on test datasets of different scales, the proposed method can quickly generate optimal decisions for continuous berth allocation and quay crane dynamic scheduling. To show the performance of the proposed method, comparative experiments with the DDPG algorithm and three classic heuristics are conducted. Compared with DDPG, the proposed method can reduce the total working time of the ships by 3 to 10 hours, and has a better performance and efficiency of convergence in the training process. For 30 ships, compared with the genetic algorithm, PSO algorithm, and a first-come-first-serve heuristics, the proposed method reduces the total working time optimization objective by 15.7%, 20.3%, and 11%, respectively, and reduces decision time by about 93% compared to the two metaheuristics.

The PPO-based method proposed in this article can fully utilize historical data, obtain and update the best strategy through interactive training in a dynamic environment, and make effective decisions for continuous berth allocation and quay crane dynamic scheduling. It has more advantages in decision-making efficiency and optimization on objectives compared to traditional learning methods and is thus more in line with the current intelligent development requirements of ports. Future research could consider using reinforcement learning in multi-level equipment joint scheduling, and cooperative game of multiple agents.

Key words: berth and quay crane joint scheduling; deep reinforcement learning; continuous berth allocation; crane dynamic scheduling; PPO algorithm

0 引言

集装箱港口是重要的海运节点,连接各国间的贸易往来。日常运营中,港口需要根据进港时间、船型、作业量、离港计划等多重因素,为计划期内的船舶合理分配有限的泊位和岸桥资源,以确保所有船舶尽快完成作业。现有泊位与岸桥分配决策通常依赖于港口工作人员的直觉和经验,容易造成船舶在港时间过长或资源浪费。并且,随着船舶大型化发展、港口吞吐量增加以及智能设备和系统的逐渐普及,大量运作数据得以积累,港口亟需更加科学和智能的泊位—岸桥调度决策方法,从而面向复杂大规模动态环境进行高效决策,进一步提升港口作业效率和资源利用率。

港口资源设备调度问题受到了众多学者的关注,但现有泊位分配研究通常将岸线离散考虑为多个泊位,不能真实刻画岸线实际情况;现有岸桥调度相关研究则大多考虑静态任务集,未能面向复杂环境下港口的实时调度需要。目前许多学者针对泊位分配及岸桥调度问题提出了各类求解方法,主要可划分为基于数学规划的精确算法及各类启发式算法。例如,BUHRKAL和ZUGLIAN^[1]建立三种模型描述离散的泊位分配问题,采用了精确算法求解,但未考虑岸桥调度。一些学者提出了分支切割

算法^[2]、列生成算法^[3,4]、拉格朗日松弛算法^[5],但是精确算法通常求解时间较长,实际大规模调度问题难以高效求解。

针对复杂大规模泊位岸桥调度,国内外诸多学者提出了许多启发式方法。KIM和MOON^[6]以船舶偏离偏好泊位成本和延迟离港成本之和最低为目标,构建了混合整数规划模型进行求解。IMAI等^[7]采用基于拉格朗日松弛算法的求解方法,并证明利用该方法并不能在多项式时间内找到问题的最优解,最终使用遗传算法进行求解。NISHIMURA等^[8]在IMAI等^[7]的研究基础上,考虑动态泊位分配及水深、泊位长度等实际约束,使用遗传算法求解。MEISEL和BIERWIRTH^[9]基于柔性连续泊位,考虑了船舶到港停泊位置偏离偏好作业位置会增加整体作业时间,以最小化作业过程中额外成本为目标,设计了混合启发式算法和邻域搜索算法。HANSEN等^[10]考虑船舶之间的属性差异,建立相关泊位分配数学模型,通过临近搜索算法对该模型进行求解。HSU和CHIAN^[11]考虑连续泊位分配问题,使用两阶段改进蛙跳算法进行求解。

随着机器学习技术的发展,有学者将强化学习方法与传统优化算法相结合应用于小规模问题求解以提升算法效果。李润佛等^[12]针对泊位调度问题提出了基于强化学习的遗传算法,利用Q-Learning算法调整遗传算法交叉变异参数提高其

搜索性能,但未考虑岸桥的集成调度;范璐璐^[13]分析了码头混合交叉调度模式,建立了以 group 为准的独立装船作业模式下的马尔科夫决策过程,设计的算法和模型应用性与的真实作业条件下有偏差;曾庆成和杨忠振^[14]对集装箱码头车辆调度问题使用 Q-Learning 进行求解,研究了不同环境下集卡调度策略。

现有泊位岸桥调度相关研究比较丰富,但还存在以下不足:

(1)考虑离散泊位,即岸线被划分为有限个数的泊位,每个泊位只能停靠一艘船舶,忽略了船舶大小对泊位分配决策的影响。

(2)仅考虑静态调度优化问题,没有建立智能体动态环境,算法不能有效适应复杂动态环境下的实时决策需要。

(3)较少考虑泊位岸桥联合调度优化,现有基于强化学习的方法仅对传统算法中的参数进行寻优,没有充分利用强化学习自适应迭代及高效决策的优势。

综上,面向复杂动态环境下港口泊位岸桥智能优化调度决策的需要,本文考虑连续泊位分配和岸桥动态调度,基于序列决策问题构建其马尔可夫决策模型(Markov Decision Processes, MDP),并提出一种高效的强化学习方法,采取结合 A2C (Actor-Critic) 神经网络框近端策略优化 (Proximal Policy Optimization, PPO) 求解该问题。本文余下内容安排如下:第1节为详细的问题描述及 MDP 模型构建;第2节是 PPO 算法设计;第3节为数值实验;第4节总结全文。

1 问题描述与 MDP 模型构建

1.1 问题描述与假设

日常运营中港口会不断收到船舶入港的请求,每艘船舶会告知其预计到港时间、船长、货量等信息。港口需要考虑岸线的动态作业情况为即将入港的船舶分配合理的靠泊位置及作业岸桥。以各船舶的总在港时间最小为目标,本文考虑连续岸线泊位分配和岸桥的动态调度,并作如下基本假设:(1)船舶达到时间已知且准时达到,船舶相关参数已知;(2)岸桥的装卸效率为一个定值;(3)每艘船舶的装卸服务时间,与船舶自身的作业任务量成正比,与被服务的岸桥总数目成反比;(4)各岸桥作业时不可相互交叉,移动范围有限、移动时不可相互跨越;(5)岸桥在其服务的船舶没有全部完成任务之前可以移动到另外一艘船舶。

1.2 马尔可夫决策过程

本文将考虑的泊位—岸桥调度问题定义为马尔可夫决策过程,可以表示为一个五元组 (S, A, P, R, γ) ,其中 S 是状态空间, A 是动作空间, P 是状态转移概率由环境决定,表示执行当前状态动作后转移到下一个状态的概率, R 为奖励函数, γ 为折扣因子。

如图1所示,在每个时间步 t ,智能体通过观察当前的环境状态 S_t 并采取动作 a_t ,获取相应的奖励 r_t 。然后,环境状态从 S_t 转换到 S_{t+1} ,智能体不断与环境进行交互并采取动作,以获得最大的累积奖励 R_t 。




图1 强化学习智能体与环境交互

1.2.1 状态空间描述

状态空间是调度过程中所有状态的集合,信息包括岸线状态、船舶状态(包括船舶任务量变化状态)、岸桥状态。如表1所示,状态空间集合表示为 $S_t = \{i_{wait}, x_{lit}, y_{it}, x_i, m_{itq}, w_i\}$,港口岸线划分为40栅格,每个栅格有两个状态;每条船的状态有两种,智能体每时刻决策4艘船舶,每艘船舶根据其船长占用多个相邻的单位岸线栅格;共20台岸桥:岸桥状态有三种,因此所有的状态空间数字化描述为: $2^{40} \times 2^4 \times 3^{20}$ 。

表1 状态空间

状态空间	数据结构	维/尺寸	数据类型	意义
i_{wait}	Array	4	bool	当前任务船舶的待分配状态
x_{lit}	Array	40	bool	岸线泊位占用情况
y_{it}	Array	4	bool	船舶进港状态
x_i	Array	4	Int	船舶靠泊位置
m_{itq}	Array	20	Int	岸桥移动状态
w_i	Array	4	Int	当前任务船舶任务量

1.2.2 动作空间描述

动作空间为智能体在当前状态下所采取动作的集合。在泊位岸桥联合调度问题中,智能体执行的动作为给当前等待船舶分配泊位和岸桥移动。如表2所示,动作空间集合为 $a_t = \{x_{i0}, x_{i1}, x_{i2}, x_{i3}, m_{qi}\}$,为了提升船舶分配的效率,动作空间设计为可同时给四艘等待船舶分配泊位,在选择动作时,第一类是给当前等待船舶分配泊位,在表格中前四行的,包括分配船舶进入40个泊位以及一个不做分配动作,智能体根据船舶信息决策船舶进港顺序,第二

类岸桥是否移动,位于表格中第五行,共有20台岸桥的3个动作,动作空间的数字化描述为 $41^4 \times 3^{20}$ 。

表2 动作空间

动作空间	数据结构	维/尺寸	类型	意义
x_{i0}	Array	41	Int	船舶0被分配的位置
x_{i1}	Array	41	Int	船舶1被分配的位置
x_{i2}	Array	41	Int	船舶2被分配的位置
x_{i3}	Array	41	Int	船舶3被分配的位置
m_{qi}	Array	20	Int	岸桥移动位置

1.2.3 奖励描述

在泊位岸桥调度问题中,为均衡每个岸桥调度和船舶的作业完成度,将完工时间奖励映射为船舶超出预计离港时间的惩罚和岸桥移动距离过大惩罚:若完工时间小于预期时间则奖励,反之惩罚,岸桥移动距离根据岸桥移动次数计算并产生惩罚,目标是 minimized 船舶在港总时间。单步获得奖励为当前决策时间 t ,当前船舶的作业完工时间奖励 c_{wi} 超出预计时间惩罚 p_{wi} 和岸桥移动惩罚 p_{miq} 之和。本文在船舶作业过程中考虑岸桥动态移动,在智能体交互过程中即时奖励设置了岸桥移动奖励及惩罚的权重 α_2 和 α_3 来限制岸桥移动的幅度。即:

$$r_{t+1} = \alpha_1 c_{wi} + \alpha_2 p_{wi} + \alpha_3 p_{miq} \quad (1)$$

考虑未来奖励的折扣因子 γ ,可得总奖励目标为:

$$R = \sum_{t=0}^K \gamma^{K-t} r_t \quad (2)$$

2 近端策略优化算法(PPO)

PPO算法通过计算策略梯度的估计值并利用随机梯度上升算法来工作,并通过随机梯度下降算法对参数进行优化^[15]。

2.1 PPO算法模型

在强化学习求解过程中,目标是获得更好的策略,而策略函数取决于学习更好的价值函数,价值函数分为状态价值函数和动作价值函数。与上述MDP模型一致,任意时刻,智能体的奖励值定义如式(3)。

$$R_t = r_t + \gamma r_{t+1} + \cdots + \gamma^{T-t} r_{T-1} + \gamma^{T-t} v_{t+1} \quad (3)$$

其中: γ 为折扣因子, T 为时间总步, r_t 为 t 决策步的即时奖励, R_t 为各个时间步的累计折扣奖励,则累计期望回报奖励 G_t 为:

$$\begin{aligned} G_t &= R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \cdots + \gamma^{n-1} R_n \\ &= R_t + \gamma G_{t+1} \end{aligned} \quad (4)$$

由于策略 π 是随机的,累计回报 G_t 为随机变量,但可计算其期望,定义状态值函数 $V(s)$ 表示状

态 s 下执行动作 a 得到的奖励期望:

$$V(s) = E_t[G_t | s_t = s] \quad (5)$$

相应的,动作价值函数指的是在特定状态下选择某种动作而具备的价值,同样为将来能够得到所有奖励的期望值,令动作值函数 $Q(s, a)$ 表示当前智能体在状态 s 下根据策略 π 选择动作 a 的优劣程度,定义为:

$$Q(s, a) = E_t[G_t | s_t = s, a_t = a] \quad (6)$$

状态价值最优值函数指在每一个状态时其状态值大于其他值函数在当前状态的值的值函数,定义为:

$$V^*(s) = \max_a V^\pi(s) \quad (7)$$

状态值函数和动作值函数的动态规划方程为:

$$V^\pi(s) = \sum_a \pi(s, a) \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V^\pi(s')] \quad (8)$$

$$Q^\pi(s, a) = \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma \sum_{a'} Q^\pi(s', a')] \quad (9)$$

基于式(5)~式(9)可得最优值函数动态规划方程:

$$V^*(s) = \max_a \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma \sum_{a'} Q^\pi(s', a')] \quad (10)$$

其中, P 为状态转移概率, s' 为状态 s 下采取动作 a 后的状态, a' 为下一动作。

算法的动作概率分布为新旧策略比值:

$$ratio_t = \frac{\log \pi_{new\theta}(s_t, a_t)}{\log \pi_{old\theta'}(s_t, a_t)} \quad (11)$$

算法优化目标函数梯度定义如下:

$$J_{PPO}^{\theta'}(\theta) = E_t[ratio_t A^{\theta'}(s_t, a_t) - \beta \cdot KL(ratio_t)] \quad (12)$$

其中, $\pi_{new\theta}(s, a)$ 作为策略训练过程中不断更新的策略, $\pi_{old\theta'}(s, a)$ 为与环境交互的旧策略,在一定迭代后,新策略的参数 θ 将更新至旧策略。 $A^{\theta'}(s, a)$ 为价值输出的优势函数,定义为:

$$A^{\theta'}(s, a) = Q(s, a) - V(s) \quad (13)$$

其中, $Q(s, a)$ 表示动作价值函数, $V(s)$ 表示状态 s 下执行动作 a 得到的奖励期望。

在PPO算法中,使用Critic网络指导Actor网络,使Actor网络往更高奖励值更新,可以用损失函数限制新策略的更新幅度,当步长较大时也可以保证策略稳定收敛,AN网络的损失函数 L^{AN} 表达式为:

$$\begin{aligned} L^{AN} &= -E_t[\min(A^{\theta'} ratio_t(\theta), \\ &\quad clip((ratio_t(\theta), 1 - \epsilon, 1 + \epsilon) A^{\theta'}))] \end{aligned} \quad (14)$$

其中: E_t 为 t 时刻交互过程中进行采样的期望函数; θ 为AN网络参数; $ratio_t$ 为 t 时刻的新旧策略概率函数; $A^{\theta'}$ 为 t 时刻的动作价值优势变量; $clip$ 为修剪函数,可以缓和策略更新速度; ϵ 为裁剪系数

将新旧策略比值限定在 $1 - \varepsilon$ 和 $1 + \varepsilon$ 区间内可以避免策略突变。

CN 用来拟合状态价值函数, θ_2 为 CN 的网络参数,令 $r_t(s, a)$ 表示状态 s 采取动作 a 的即时奖励, CN 的损失函数 L^{CN} 表达式为:

$$L^{CN} = (r_t(s, a) + \gamma V(s') - (V(s)))^2 \quad (15)$$

在 PPO 算法中,使用随机梯度上升更新,利用 π_θ 进行采样,得到样本训练参数 θ , θ' 是固定的,避免重复采样,并且引入 KL 散度(衡量概率相似性的度量指标)放进梯度中进行计算,定义如下:

$$E_t[KL(\theta, \theta')] \leq \delta \quad (16)$$

其中 δ 是设置的一个值,如果 θ 与 θ' 相对熵小于这个值,则认为两个概率分布之间的差距不大。依据这个目标函数,就可以使用 $\theta \leftarrow \theta + a \nabla J(\theta)$ 来更新参数,最终使收益的期望值最终收敛到最大。

2.2 PPO 算法步骤

PPO 算法中通过在网络参数为 θ_{old} 的 Actor 网络中产生状态转换序列,在该序列中抽取小样本进行训练,设置间隔固定的时间,通过策略梯度上升和均方误差下降方法更新参数, PPO 算法的超参数^[16]设置如表 3 所示。

表 3 算法参数设置

序号	符号	含义	大小
1	αA	Actor 网络学习率	10^{-5}
2	αC	Critic 网络学习率	10^{-5}
3	ε	Clip 截断系数	0.2
4	γ	折扣因子	0.99
5	n_steps	更新环境间隔时间步	100
6	batch_size	batch 大小	256

算法总体流程如图 2 所示:




图 2 PPO 算法流程图

3 算法测试与分析

本文使用开源 Python 库 Pytorch 实现泊位—岸桥调度的 PPO 算法,实验环境配置 Intel(R) Core(TM) i5-1130@3.2HZ。

3.1 案例描述

船期数据采用上海某集装箱港口实际运营数据,选取计划周期内即将到港的 30 艘集装箱船舶数据进行模型训练,包括船舶长度、任务量和预计到港时间,船长约束岸桥的使用数量,全岸线共 20 台岸桥,每台岸桥最大移动距离为 200m,岸桥间隔大于为 50m,岸桥效率为 100 箱/小时。

3.2 基于 PPO 算法的泊位—岸桥调度

3.2.1 训练过程分析

每个 episode 为一次训练过程,代表与环境交互 72 steps,智能体每间隔 100 steps 更新一次模型。训练过程中每 1000 次 episodes 保存一次阶段训练结果,表示为 checkpoint。

整体分析了 30 条船在不同间隔时间段训练模型的作业时间。设置每时刻决策 4 艘船舶的经验容量,通过调整超参数实验发现,当每时刻船舶决策过少时会导致船舶动态决策的效率较低,船舶决策数量过大则动作空间和状态空间维度过大导致整体奖励收敛时间较长。在 checkpoint = 000001 - 001001 训练初期奖励值为 -25.37,船舶作业时间超出预计作业离港时间;在 checkpoint = 0002001 阶段奖励结果逐渐开始递增至正值 12.19,船舶的作业时间不再超出预计离港时间,调度结果的作业时间为 122h;在 checkpoint = 0003001 - 005001 阶段,作业时间逐渐优化至 112h,奖励曲线开始收敛并趋于平缓。

3.2.2 训练结果分析

本文采用相对平均累计奖励值的变化来评估 PPO 算法训练过程,即获取多个回合的累计奖励后,计算当前回合累计奖励的平均值,全部完成指定步数后,计算每一轮训练对应的平均累计奖励值。

如图 3 所示,在训练初期由于智能体缺乏对环境认知,奖励值为负数,损失函数值较高;随着训练的进行智能体不断与环境交互,相对平均奖励值逐渐增加,在迭代 6 万步之后奖励值增加到 107.6 并趋于稳定,智能体已学习到满足系统约束下的稳定策略,此时损失函数值逐渐趋于最小化。奖励与调度目标呈正相关,奖励的增加表示每条船舶完工时

间的缩短和岸桥移动的减少。




图3 PPO 算法训练相对平均累计奖励和损失对比

3.2.3 测试过程及结果分析

本文选取了不同规模案例数据进行测试,以30艘船舶的泊位和岸桥调度为例,图4为船舶V1-V30的泊位调度甘特图,横轴为船舶在港作业时间,纵轴为船舶停泊位置;图5为相应的岸桥调度甘特图,分布在岸线0-1000的位置,岸桥在船舶进港之后一直处于作业移动状态。本文在船舶作业过程中考虑岸桥动态移动,在智能体交互过程中即时奖励设置了岸桥移动奖励及惩罚的权重 α_2 和 α_3 来限制岸桥移动的幅度。




图4 船舶调度甘特图




图5 岸桥动态调度甘特图

智能体根据船舶情况分配调度岸桥给船舶,其中船舶V1,V2,V4,V10,V14,V17,V18,V23的岸桥数量在作业过程中发生了变化,岸桥的动态调度有利于将船舶靠泊位置时间和岸桥效率进行优化匹配,提高资源利用效率。特别的,添加了岸桥移动惩罚后与未添加该惩罚时的结果进行对比,船舶总完工时间提前3h,且有效避免了船舶靠泊后等待岸桥前来作业的情况。

3.3 算法对比分析

3.3.1 PPO 算法与其他强化学习算法对比

为了验证PPO算法相对于其他强化学习算法具备更好的优化效果,选取DDPG算法进行对比实验,两种算法的奖励函数值以及损失函数值如图6所示。




图6 PPO 与 DDPG 算法训练相对平均奖励与损失对比

由图6可知,PPO算法的奖励函数值收敛速度以及最终收敛效果均优于DDPG算法,DDPG算法的损失函数未能达到目标最小化。在测试算例上,PPO算法测试的不同算例的船舶作业时间结果分别为46h,87h和108h,而DDPG生成的测试相较于PPO算法结果加快约6.5%~10%的作业时间。因此,PPO算法相较于DDPG算法而言,其收敛速度和计算效果都更具优势。

3.3.2 PPO 算法与传统算法对比

为了验证本文提出的算法在泊位岸桥调度实际运营决策中的有效性和优越性,选择四组算例分别包括10条、15条、20条和30条船舶,从完工时间(TCT)和算法计算时间(CPU)两个方面,将PPO算法调度结果分别与遗传算法(GA)、粒子群算法(PSO)以及先来先服务调度算法(FCFS)^[17,18]的结果进行了对比分析。

从表4中可以看出,随着算例规模的逐渐增大,同样算例及相关约束环境下,RL与GA和PSO相比,在算法计算速度方面提升幅度较大,船舶规模 $N=30$ 时,RL运行时间为4.6495s,GA为68.450s,运行速度提升了93.21%,PSO运行时间为66.817s,运行速度提升了93.01%,在小规模算例也有较快测试速度;在作业时间对比方面可知,RL分别比GA和PSO优化了15.7%和20.3%的在港作业时间。与先来先服务规则对比,由于FCFS算法规则较简单所以计算也较快完成,但是在完工时间的优化方面,例如测试 $N=30$ 算例,RL比FCFS优化了43%左右。

表4 算法性能对比数据表

算例	PPO		GA		PSO		FCFS	
	TCT (h)	CPU (s)	TCT (h)	CPU (s)	TCT (h)	CPU (s)	TCT (h)	CPU (s)
$N=10$	42	1.54	44	13.31	47	12.10	50	0.02
$N=15$	46	1.98	50	19.83	54	16.97	72	0.02
$N=20$	87	2.25	92	48.53	100	45.72	90	0.02
$N=30$	108	4.65	125	68.45	130	66.82	122	0.02

4 总结

本文考虑集装箱港口的连续泊位分配和岸桥动态调度联合优化,提出了一种基于深度强化学习近端策略优化PPO算法。将该问题视为一个序列决策问题,构建其马尔可夫决策过程,设计了合理的状态空间、动作空间和奖励函数。训练和测试结果表明,本文所提出的PPO算法能够充分利用历史数据,通过动态环境与智能体进行交互训练求得最佳奖励策略,合理安排连续泊位分配与岸桥动态调度方案,与DDPG算法和三类启发式算法相比在决策效率和优化目标上都更具优势,更符合当前港口的智能化发展要求。

未来研究可以考虑将强化学习算法运用在多层级设备联合调度中,也可以进一步考虑多智能体之间的合作博弈问题。

参考文献:

- [1] BUHRKAL K, ZUGLIAN S. Models for the discrete berth allocation problem: A computational comparison [J]. Transportation Research Part E: Logistics and Transportation Review, 2011, 47(4): 461-473.
- [2] 郑红星,朱徐涛,李振飞. 双向航道集装箱港口船舶调度优化算法[J]. 计算机应用, 2021, 41(10): 3049-3055.
- [3] JIA S, LI C L, XU Z. Managing navigation channel traffic and anchorage area utilization of a container port [J]. Transportation Science, 2019, 53(3): 728-745.
- [4] LIU B, LI Z C, WANG Y, et al. Short-term berth planning and ship scheduling for a busy seaport with channel restrictions[J]. Transportation Research Part E: Logistics and Transportation Review, 2021, 154: 102467.
- [5] LI S Q, JIA S. The seaport traffic scheduling problem: Formulations and a column-row generation algorithm[J]. Transportation Research Part B: Methodological, 2019, 128: 158-184.
- [6] KIM K H, MOON K C. Berth scheduling by simulated annealing[J]. Transportation Research Part B: Methodological, 2003, 37(6): 541-560.
- [7] IMAI A, NISHIMURA E, PAPADIMITRIOU S. The dynamic berth allocation problem for a container [J]. Transportation Research part B: Methodological, 2001, 35(4): 401-417.
- [8] NISHIMURA E, IMAI A, PAPADIMITRIOU S. Berth allocation planning in the public berth system by genetic algorithm[J]. European Journal of Operational Research, 2001, 131(2): 282-292.
- [9] MEISEL F, BIERWIRTH C. Heuristics for the integration of crane productivity in the berth allocation problem [J]. Transportation Research Part E: Logistics and Transportation Review, 2009, 45(1): 196-209.
- [10] HANSEN P, ÖĞÜZ C, MLADENOVIC N. Variable neighborhood search for minimum cost berth allocation [J]. European Journal of Operational Research, 2008, 187(1): 636-649.
- [11] HSU H P, CHIAN T L. An improved shuffled frog-leaping algorithm for solving the dynamic and continuous berth allocation problem (DCBAP) [J]. Applied Sciences, 2019, 9(21): (Article)4682.
- [12] 李润佛,张新宇,李俊杰,等. 基于强化学习的自学习遗传算法在船舶调度中的应用[J]. 大连海事大学学报, 2022, 48(3): 20-30.
- [13] 范璐璐. 混合堆场自动化集装箱码头 L-AGV 调度 IM-ε-Q 算法[D]. 大连:大连理工大学, 2018.
- [14] 曾庆成,杨忠振. 集装箱码头集卡调度模型与 Q 学习算法[J]. 哈尔滨工程大学学报, 2008, 29(1): 1-4.
- [15] 石欣,秦鹏杰. 基于平方根无迹卡尔曼神经网络的铝电解工耗模型[J]. 仪器仪表学报, 2016, 37(S1): 7-15.
- [16] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[J/OL]. arXiv, 2017:1707.06347v2[2023-01-10]. <https://arxiv.org/pdf/1707.06347v2>.
- [17] 焦小刚,郑斐峰,徐寅峰,等. 考虑泊位疏浚的连续型泊位和动态岸桥联合调度[J]. 运筹与管理, 2020, 29(2): 47-57.
- [18] 程世辉,张林. 先来先服务(FCFS)调度算法响应时间的计算[J]. 河南教育学院学报:自然科学版, 2006, 15(3): 20-22.